

A Survey on Graph Neural Networks

Onurcan Ünsal
University of Augsburg
Augsburg, Germany
onurcan.uensal@student.uni-augsburg.de
Supervisor: Dr. Shahin Amiriparian

ABSTRACT

In der folgenden Arbeit geht es um die Anwendung und Entwicklung von Graph Neural Networks (GNN) in Bezug auf den Themenbereich des Machine Learnings. Durch die Anwendung von Graph Neural Networks werden in vielen Bereichen des Machine Learnings deutlich bessere Ergebnisse erzielt, als die dafür verwendeten state-of-the-art Methoden. Diese werden in der Physik, Chemie, Biologie, Empfehlungssystemen und der Verarbeitung von Texten und Bildern angewendet. Im Folgenden wird die Entwicklung der letzten Jahre und die dabei erzielten Ergebnisse von Graph Neural Networks beschrieben, aufgrund der stetigen Zunahme von Anwendungen im Bereich des Machine Learnings.

1. EINFÜHRUNG

Die Nachfrage der Aufgaben für das Maschinelle Lernen (ML) ist in den letzten Jahren rasant angestiegen, da diese ideal für große Datensätze sind. ML ist ein in sich entwickelnder Zweig von Algorithmen, die die menschliche Intelligenz, anhand dem Lernen aus der Umgebung, nachahmen sollen. Diese sind ein Meilenstein im Bereich von Big Data. Zahlreiche Methoden, die auf maschinellen Lernen basieren, werden in vielen Themenbereichen eingesetzt. Zu diesen Bereichen zählen unter anderem Objekterkennung, Finanzwesen und medizinische Anwendungen. [133] Viele Beziehungen zwischen Daten in verschiedenen Bereichen der Ingenieurwissenschaften und Naturwissenschaften, wie Molekularbiologie, Chemie und Datamining können als Graphen dargestellt werden. Zudem ist die sehr hohe Anzahl an Informationen, die stetig zunimmt, welche meist viele komplexe Beziehungen und Interaktionen enthalten, ein wichtiger Aspekt. Diese Daten werden zwischen Systemen transportiert. Für die graphische Darstellung und das Verstehen des Transports wird ein neuartiges Modell der neuronalen Netze angewandt. Das dafür verwendete Modell heißt Graph Neural Network. Für die Verwendung von GNNs gibt es viele Gründe. Diese werden im 3. Absatz genauer erläutert. Zu diesen zählen die Fähigkeit graphisch strukturierte Daten zu ana-

lysisieren, Graphen zu klassifizieren und Knoten und Links oder Kanten vorherzusagen. [5] [7]

2. GRAPH NEURAL NETWORKS (GNN)

Die Darstellung von Beziehungen zwischen Daten, sei es in Bereichen der Wissenschaft und im Bereich des Ingenieurwesens, zum Beispiel Computer Vision, Molekularchemie und Molekularbiologie, werden Graphen verwendet.

Graph Neural Networks (GNNs) ist ein neues Modell der neuronalen Netzwerke, die die existierenden Methoden zu neuronalen Netzwerken erweitert haben, um Graphen, seien sie azyklisch, zyklisch, gerichtet oder ungerichtet, unmittelbar zu verarbeiten. GNNs sind deep learning basierte Methoden, die an Graphdomänen arbeiten. Aufgrund der überzeugenden Performance wurden GNNs in letzter Zeit zu einer weit verbreiteten Methode in der Graphenanalyse. [7] Die Laufzeit dieser Methoden sind wohl überlegt und hängen somit von der Anzahl der Knoten n und der Anzahl des m -dimensionalen euklidischen Raumes ab. [5]

3. GRÜNDE ZUR VERWENDUNG VON GNNs

Wieso hat die Anzahl an Verwendungen von GNNs in den letzten Jahren so stark zugenommen und was sind die Gründe zur Verwendung von GNNs im Bereich des Machine Learnings? Der erste Aspekt zur Verwendung von Graphen im Bereich von Machine Learning ist, das Ermöglichen komplexer Darstellungen von Beziehungen und Interaktionen zwischen Elementen besser wiederzugeben.

Die Hauptgründe sind jedoch die Vorhersage von Knoten und Kanten und die Klassifikation von Graphen. [7] Die Vorhersage von Knoten ist vorteilhaft im Bereich der Verkehrsnetze, denn diese können Hauptknotenpunkte im Verkehrsnetz prognostizieren. [66] [67] [68] [69] Die Vorhersage von Kanten/Links in einem Graphen sind in sozialen Netzen von großer Bedeutung. Aufgrund dessen können durch die Verwendung der Knotendaten (z. B. Informationen über einen User, sei es Ort, Hobby, etc.) vorhergesagt werden, ob eine Person eine andere Person kennt oder nicht, um dadurch einen neuen Link oder eine Verbindung zwischen den Personen zu generieren. [72] [73] Die Klassifikation von einem Graphen spielt in der Medizin eine außergewöhnlich wichtige Rolle, denn anhand dieser Klassifikation kann vorhergesagt werden, ob ein Molekül oder ein Medikament, welches ein ähnliches Muster aufweist wie ein in der Vergangenheit verwendetes Medikament, für eine Krankheit oder Behandlung in Frage kommt. [128]

Ein weiterer Aspekt zur Verwendung von GNNs ist die unmittelbare Verarbeitung der Daten. In der Vergangenheit

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. To copy otherwise, to republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee.

Seminar Computational Intelligence. Chair of Embedded Intelligence for Health Care and Wellbeing, University of Augsburg, Germany
Copyright 2021.

wurden im Bereich des Machine Learning Convolutional Neural Networks (CNNs) verwendet. Diese erreichten bemerkenswerte Ergebnisse. [129] [130] [131] Jedoch können CNNs nur an euklidischen Daten operieren, die in einem zweidimensionalen Grid oder einer ein-dimensionalen Sequenz angegeben sind. [11] [132] Da jedoch in der Natur die zu verarbeiteten Graphen nicht immer in einem bestimmten Grid vorliegen und somit nicht direkt als Eingabe von CNNs verwendet werden können, müssen diese transformiert werden, um diese als valide Eingabe verwenden zu können. Der Vorteil von GNNs liegt darin, in Gegensatz zu CNNs, dass diese die Graphdaten meist ohne Transformation unmittelbar anwenden können, da bei der Transformation von Daten Informationen verloren gehen oder verändert werden könnten. [5]

4. ARTEN VON GRAPH NEURAL NETWORKS

Im folgenden Abschnitt wird die Taxonomie von Graph Neural Networks vorgestellt. GNNs werden kategorisiert in Recurrent Graph Neural Networks (RecGNNs), Convolutional Neural Networks (ConvGNNs), Graph Autoencoders (GAEs) und Spartial-Temporal Graph Neural Networks (STGNNs). ConvGNNs werden unterschieden zwischen spektralen Methoden und räumlichen Methoden. GAEs werden in Netzwerkeinbettung und Graphgenerierung unterteilt. [132]

4.1 Recurrent Graph Neural Networks

Diese Art von GNNs sind meist Pionierarbeiten von GNNs. Das Ziel von RecGNNs ist es, Knotenrepräsentationen mit rekurrenten neuronalen Architekturen zu lernen. RecGNNs nehmen an, dass ein Knoten so lange Nachrichten oder Informationen mit seinem Nachbarn austauscht, bis ein stabiles Gleichgewicht erreicht ist. Diese Art von GNNs sind konzeptionell wichtig und inspirieren spätere Forschungen zu ConvGNNs. Hinzu kommt, dass die Idee der Nachrichtenübermittlung von den räumlich basierten ConvGNNs übernommen wird. [132]

4.2 Convolutional Graph Neural Networks

ConvGNNs verallgemeinern die Operation der Faltung von Gitterdaten auf Graphdaten. Der Leitgedanke besteht darin, dass die Darstellung eines Knotens v erzeugt wird, indem durch Aggregation seiner eigenen Merkmale x_v und der Merkmale seiner Nachbarknoten x_u , wobei $u \in N(v)$ ist. Verglichen mit RecGNNs werden bei ConvGNNs mehrere Graphfaltungsschichten gestapelt, um hochrangige Knotenrepräsentationen zu extrahieren. ConvGNNs spielen eine wichtige Rolle beim Aufbau vieler komplexer GNN-Modelle. Diese werden für die Klassifikation von Graphen und Knoten verwendet. [132]

4.3 Graph Autoencoders

GAEs sind unüberwachte Lernverfahren, die Knoten/Graphen in einen latenten Vektorraum kodieren und aus den kodierten Informationen Graphdaten rekonstruieren. Die vorliegende Art von GNNs werden zum Lernen von Netzwerkeinbettungen und generativen Graphverteilungen verwendet. Für die Netzwerkeinbettung lernen GAEs latente Knotenrepräsentationen, anhand der Rekonstruktion von Graphstrukturinformationen, wie zum Beispiel die Graph-Adjazenzmatrix. Für die Generierung von Graphen erzeugen Methoden sukzessiv Knoten und Kanten eines Graph. [132]

4.4 Spartial-Temporal Graph Neural Networks

Dieses Modell intendiert darauf verborgene Muster aus räumlich-zeitlichen Graphen zu lernen. Diese Fähigkeit wird in einer Vielzahl von Anwendungen immer wichtiger, wie die Vorhersage von Verkehrsgeschwindigkeiten [149], der Antizipation von Fahrmanövern [118] und der Erkennung von menschlichen Handlungen [150]. Die Schlüsselidee in STGNNs besteht darin, dass räumliche und zeitliche Abhängigkeit gleichzeitig zu berücksichtigen sind. Aktuelle Ansätze integrieren Graphenfaltung, um die räumliche Abhängigkeit zu erfassen anhand von RNNs oder CNNs, für die Modellierung der zeitlichen Abhängigkeit. [132]

4.5 Point Graph Neural Networks

Die drei dimensionale Objektdetektion spielt ebenfalls im Bereich des Machine Learnings eine wichtige Rolle. Um diese Detektion von Objekten bestmöglich realisieren zu können, wird eine bestimmte Art von Graph Neural Networks verwendet, diese nennt man Point Graph Neural Network (Point-GNN). Die Erstellung von einem Point Graph Neural Network benötigt drei wichtige Komponenten. Meist werden Datensätze in Punktwolken (Point-Cloud) dargestellt, da anhand dieser Punktwolke jedes drei dimensionale Objekt dargestellt werden kann, sogar wenn diese in der Natur nicht visuell darstellbar sind. Anhand dieser Punktwolke wird ein Graph erstellt mit allen Kanten/Relationen, mit den dazugehörigen Knoten. Zudem wird ein Graph Neural Network mit T Iterationen erstellt, welches für die Objekt Detektierung benötigt wird. Anschließend werden die Begrenzungsrahmen zusammengeführt und gewertet. [2]

5. ANWENDUNGEN VON GRAPH NEURAL NETWORKS IN MACHINE LEARNING

Graph Neural Networks wurden in den letzten Jahren immer beliebter. Eines der Gründe ist die Vielseitigkeit dieser Methode, da diese in vielen Bereichen des Machine Learning angewendet werden kann. Die Anwendungen von GNNs mit den jeweiligen Themenbereich und dem dazugehörigen Paper kann in der *Table 1* zu entnehmen. In den hier gezeigten Themenbereichen ist deutlich zu sehen, wie flexibel GNNs sind. Die erzielten Ergebnisse der durchgeführten Experimente, welche in den jeweiligen Arbeiten vorliegen, sprechen für die Verwendung von GNNs.

5.1 GNN in der 3D Objektdetektion

Die Erkennung von Übereinstimmungen von Punkten, die Abschätzung der drei-dimensionalen Struktur und die Position auf einem Bild spielen eine große Rolle und sind ein wichtiges Thema im Bereich des Machine Learning. Das heißt, dass das Neuronale Netzwerk übereinstimmende und nicht zusammenpassende Punkte auf einem Bild erkennt und somit bestimmen kann, ob dieser Punkt der selbe Punkt, wie auf dem Bild ist oder nicht. Es gibt viele state-of-the-art Methoden, die diese Übereinstimmungen bestimmen können, jedoch gelingt dies einer neuartigen Methode mit deutlich besseren Ergebnissen bei den dafür durchgeführten Experimenten. Diese neue Methode nennt sich SuperGlue.

SuperGlue erkennt Übereinstimmungen zwischen zwei Punkten und zudem die Verwerfung von zwei nicht passenden Punkten deutlich besser als die herkömmlichen Techniken. Diese Verbesserung geschieht anhand der Verwendung von Graph Neural Networks. Der SuperGlue besteht hauptsächlich

Table 1: Anwendungen von GNNs [7]

Bereich	Anwendung	Referenzen
Graph Mining	Graph Mining, Graph Clustering	[21], [22] [23], [24], [25]
Physik	Modellierung Physikalischer Systeme	[26], [27], [28], [29], [30], [31], [32]
Chemie	Molekulare Fingerprints, Chemische Reaktion Vorhersage	[33], [34] [35]
Biologie	Protein Interface Vorhersage Vorhersage Nebenwirkungen Krankheiten Klassifikation	[36] [37] [38]
Wissensgraph	Knowledge Base (KB) Fertigstellung Knowledge Graph (KG) Angleichung	[39], [40], [41] [42], [43], [44]
Generation	Graph Generierung	[45], [46], [127], [48], [49], [50], [51], [52], [53]
Optimierung Kombinatorik	Optimierung Kombinatorik	[54], [55], [56], [57], [58], [59], [60], [61], [62], [63], [64], [65]
Verkehrsnetzwerke	Vorhersage Verkehrsstatus	[66], [67], [68], [69]
Empfehlungssysteme	Vorhersage User-Item Interaktion Soziale Vorschläge	[70], [71] [72], [73]
Andere (strukturell)	Aktienmarkt Software-Definierte Netzwerke AMR Graph zu Text	[74], [75], [76], [77], [78] [79] [80], [81]
Text	Text Klassifikation Sequenzkennzeichnung Neuronale Maschinelle Übersetzung Relation Extraction Event Extraction Faktencheck Fragen Beantwortung Relationale Argumentation	[82], [83], [84], [85] [86], [87] [88], [89], [90] [91], [92], [93], [94] [95], [96] [97], [98], [99] [100], [101], [102], [103], [104] [105], [106], [107]
Bilder	Verstehen Sozialer Beziehungen Bilder Klassifikation Beantwortung Visueller Fragen Objekterkennung Interaktionserkennung Region Klassifikation Semantische Segmentierung	[108] [109], [110], [111], [112], [113] [114], [115], [116] [117], [118] [119], [120] [121] [122], [123], [124], [125]
Andere (nicht-strukturell)	Programm Verifikation	[126], [127]

lich aus zwei wichtigen Komponenten. Die erste Komponente ist ein Attentional Graph Neural Network und die zweite Komponente/Schicht ist der Optimal Matching Layer. [134]

Die Kombination von SuperGlue mit SuperPoint [140] übertrifft die state-of-the-art Methoden für die Posenschätzung in Innenräumen und im Freien. Die Experimente sind in drei Bereiche eingeteilt. Die Homographie Schätzung, Schätzung im Innenbereich und die Schätzung im Außenbereich. Der Datensatz für die Homographie Schätzung entsteht, indem Bilderpaare erzeugt werden, in denen zufällige Homographien ausgewählt und zufällige photometrische Verzerrungen auf realen Bildern angewendet wird. Für die Durchführung der Experimente im Innenbereich wird ScanNet [141] verwendet. Dies ist ein groß angelegter Datensatz für Innenräume bestehend aus monokularen Sequenzen mit Grundwahrheitsposen und Tiefenbildern, sowie gut definierten Trainings-, Validierungs-, und Test-Splits, die verschiedenen Szenen entsprechen. Für die Schätzung des Außenbereichs wird der

PhotoTourism Datensatz verwendet. Dieser ist Teil des CV-PR'19 Image Matching Challenges [145] und ist eine Teilmenge des YFCC100M Datensatzes [146] und enthält Grundposen und spärliche 3D-Modelle, die mit einem handelsüblichen SfM-Tool [142] [143] [144] erzielt wurden. Die Ergebnisse der Experimente zeigen, dass SuperGlue in den drei Bereichen bessere Ergebnisse erzielt als alle anderen state-of-the-art Methoden, die für lokales Feature Matching verwendet werden. [134]

5.2 Vorhersage der Lebenserwartung von Krebspatienten

Heutzutage spielt die Vorhersage oder die Lebenserwartung von Menschen nach einer schwerwiegenden Krankheit eine sehr ausschlaggebende Rolle. Um diese so genau wie möglich zu gestalten werden Multimodale Graphische Neuronale Netze (MGNN) genutzt. Diese Multimodale Graphische Neuronale Netze werden für die Bestimmung für die

Überlebenschancen von Krebskranken Patienten (2020) angewendet. Um die Lebenserwartung von krebskranken Patienten zu bestimmen gibt es heutzutage mehrere Methoden. Jedoch wurde durch die Anwendung von Graph Neural Networks diese Prognose deutlich verbessert. Bei den durchgeführten Experimenten wurden Datensätze¹ von echten Patienten mit Brustkrebs verwendet. In diesen Experimenten wurden mehrere state-of-the-art Methoden verwendet, um die Überlebenschance von krebskranken Patienten zu ermitteln oder vorherzusagen. Folgende state-of-the-art Methoden wurden mit den MGNN verglichen: LR [14], RF [15], SVM [16], MDNNMD [17]. Es wurden die real-world Brustkrebs und Lungenkrebs Datensätze verwendet. Die erzielten Ergebnisse zeigen deutlich, dass zum Beispiel die Accuracy (Richtigkeit) um über zehn Prozent besser ist, als die zweithöchste Accuracy der MDNNMD-Methode. [3]

5.3 Graph Neural Networks zur Erkennung von 3 dimensionalen Objekten in der Punktwolke

Punktwolken oder auch Point-Clouds genannt sind ein weit verbreitetes Format, welches für 3D Sensoren verwendet wird. Um das dreidimensionale Umfeld zu konstruieren wird eine dreidimensionale Darstellung von Punkten benötigt. Dies geschieht mit Hilfe von Point-Clouds, da diese die effektivste Methode ist, um dreidimensionale Objekte darzustellen. [1]

Die eingelesen/erkannten Objekte werden mittels einer Point-Cloud dargestellt. Anhand dieser wird dann ein Graph Neural Network (GNN) erstellt. Als Eingabe erwartet ein GNN einen Punktgraphen (Point-Cloud). Die Kanten, die in der Point-Cloud die Nachbarnpunkte verbinden, werden in dem GNN eine Kante. Die Punkte in der Point-Cloud werden als Knoten in den GNN übernommen. Das GNN verwendet alle Graphkanten in jeder Schicht, vermeidet dabei aber wiederum Gruppierungen. In dieser Methode wird eine besondere Art von GNNs verwendet. Diese heißen Point Graph Neural Networks. Ein Point Graph Neural Network ist eine Methode oder eine Variante des GNNs, die es dem Nutzer erlaubt anhand einem Shot mehrere Objekte zu erkennen.

In den durchgeführten Experimenten werden mehrere state-of-the-art Methoden, wie zum Beispiel VoxelNet [135], SE-COND [136], PointPillars [137], PointRCNN [138] und STD [139], verwendet und mit der Point-GNN verglichen. In diesem Experiment werden drei verschiedene Objekte verwendet - ein Fußgänger, ein Radfahrer und ein Fahrzeug. Jeder dieser Experimente wird mit je drei Lernraten durchgeführt.

Bei der Durchführung der Experimente erhält man folgende Ergebnisse: Die Methode des Point-GNN erkennt Fahrzeuge und Radfahrer besser als alle bisherigen Methoden, die zur Erkennung von dreidimensionalen Objekten verwendet werden. Bei der Birds Eye View Objekt Erkennung von Fahrzeug und Radfahrer ist der Point-GNN deutlich besser als die state-of-the-art Methoden. Lediglich die Erkennung von Fußgängern fällt schlechter aus, als die der bisherigen Methoden. Dies könnte daran liegen, dass die Knoten nicht dicht genug aneinander sind, um genaue Begrenzungen zu bestimmen.

Trotz allem zeigen die durchgeführten Experimente

¹Die dafür verwendeten Datensätze sind verfügbar unter <http://www.cbiportal.org/>

deutlich, dass anhand des Graph Neural Networks eine Steigerung der Genauigkeit von dreidimensionalen Objekten geboten wird. Letztendlich zeigen die Ergebnisse aus den jeweiligen Experimenten, dass durch die Verwendung von GNNs - hier: Point Graph Neural Networks - deutlich bessere Ergebnisse erzielt werden, als mit den aktuellen state-of-the-art Methoden. [2]

5.4 GraphCovidNet: GNN Model zur Erkennung von COVID-19

In den letzten Jahren hat das Corona Virus die ganze Welt erreicht und kostete vielen Menschen das Leben. Eines der Hauptprobleme des Virus war es diese richtig zu detektieren, da die dafür verwendeten Schnelltests nur mit einer Wahrscheinlichkeit von circa 80 % das Virus erkennen können.

Ein weiteres Problem der Tests war die Inkubationszeit von dem Corona Virus, denn dieser lag zwischen 10-14 Tagen, laut dem Robert-Koch Institut [17]. Die mittlere Inkubationszeit (Median) wird in den meisten Studien mit 5-6 Tagen angegeben.

Aufgrund dessen entstand ein großes Problem, falls ein Patient oder eine Person sich mit dem Virus infiziert hat und dieser einen Test durchgeführt hat, sei es einen Antigen-Schnelltest oder einen langsamen PCR-Test (Polymerase-Ketten-Reaktion), war es möglich, dass dieser negativ ausfällt, da die Inkubationszeit ungefähr zwei Wochen betrug. Dies war ein markantes Problem, welches sich in Zukunft verhindern lassen könnte. Denn anhand von GNNs können Graphen klassifiziert werden und somit ist es möglich die Krankheit vorherzusagen und dementsprechend ist die Inkubationszeit des Virus weniger relevant und falsche Testergebnisse demnach vermeidbar, um die Anzahl der Infizierten korrekt zu skalieren. GraphCovidNet ist ein GNN basiertes Model und erkennt anhand CT-Scans und Röntgenbilder der Brust, ob ein Patient oder eine Person an dem COVID-19 Virus erkrankt ist oder nicht.

Die für den GraphCovidNet verwendeten Datensätze sind SARS-COV-2 CT-Scan Datensatz [147], COVID-CT Datensatz [148], eine Kombination von Covid-Brust-Röntgen Datensätzen, Brust Röntgenbilder Datensatz und CMSC-678-ML Projektdatensatz.

Die an den oben genannten Datensätzen durchgeführten Experimente zeigen deutlich, dass das GraphCovidNet Model eine Accuracy von mindestens 99 % erreicht. In den Datensätzen SARS-COV-2 CT-Scan und COVID-CT erreicht das Model eine Accuracy von 100 %. Das entspricht einer vollständig korrekten Vorhersage der Erkrankung. Die erreichte Accuracy zeigt, dass das Problem der Inkubationszeit, anhand von GNNs, deutlich besser zu handeln ist als mit den aktuell durchgeführten Methoden. [8]

5.5 Weitere nennenswerte Entwicklungen von GNNs im Bereich des Machine Learnings

GNNs werden in der Medizin für die Vorhersage von Diagnosen verwendet. GNDP (Graph Neural Network-Based Diagnosis Prediction) wurden dafür entwickelt. GNDPs sind in der Lage den zukünftigen Gesundheitsstatus eines Patienten, anhand Patientendaten, die in der Vergangenheit entstanden sind, vorherzusagen. [18]

Natural Language Processing (NLP) spielt im Bereich des Machine Learning eine wichtige Rolle. GNNs werden im Bereich des NLP angewendet, da diese für die Klassifikation

von Texten [82] [83] [84] [85] eingesetzt werden. Die dafür verwendete TextING Methode klassifiziert Texte anhand von GNNs. Die Durchführung der Experimente erfolgte anhand von verschiedenen Datensätzen. Verglichen wird die Methode mit den aktuellen state-of-the-art Methoden. Dabei erzielt TextING die besten Ergebnisse. [19]

Die Eigenschaft der Klassifikation anhand von GNNs wird im Bereich der Medizin, wie im vorigen Absatz genannt, oft verwendet. Graph Convolutional Neural Networks (GCNNs) werden für die Klassifikation von Krebs verwendet. Anhand dieser kann der Krebstyp bestimmt werden. Dabei werden unstrukturierte Genexpressionen als Eingabe übergeben und das dafür verwendete Modell klassifiziert diese in einen der 33 Krebsarten. [20]

6. OFFENE PROBLEME

Trotz der beachtlichen Ergebnisse von GNNs, gibt es offene Fragen zu dieser Methode. Einerseits sind GNNs Black Boxes. Das heißt, dass GNNs eine Eingabe erhalten und eine Ausgabe liefern jedoch ist der Prozess zwischen der Eingabe von Daten und Ausgabe von Daten undurchsichtig. Ein weiteres Problem sind die komplexen Datenstrukturen. Das liegt daran, dass der Zuwachs von sozialen Netzwerken im Internet enorm angestiegen ist und immer noch weiter ansteigt und die aktuellen Methoden unzureichend sind für die Menge an Daten, was dazu führt, dass die aktuellen Methoden stetig verbessert werden müssen. [7]

7. ZUSAMMENFASSUNG

GNNs sind ein Modell der neuronalen Netzwerke, damit Graphen unmittelbar verarbeitet werden können. In den letzten Jahren wurden GNNs immer gefragter und auch leistungsfähiger. Die Performance der GNNs wird in den oben genannten Experimenten und Anwendungen deutlich unterstrichen, da diese beträchtliche Resultate erzielen, im Vergleich zu den aktuellen state-of-the-art Methoden. Es gibt verschiedene Modelle von GNNs, jedes Modell erzielt in dem jeweiligen Themenbereich signifikante Ergebnisse. Die Vorhersage von Knoten und Kanten, anhand von GNNs, finden in vielen Themenbereichen ihren Platz und es sind zahlreiche Anwendungen genannt worden, die die Anpassungsfähigkeit der GNNs beweisen. Die Klassifikation von Graphen bieten zudem viele Vorteile in unzähligen Bereichen der Medizin, Biologie und Molekularchemie. Graph Neural Networks bieten viele Vorteile und erzielen in vielen Bereichen die besten Ergebnisse, im Vergleich zu den aktuell verwendeten Methoden.

8. AUSBLICK

Graph Neural Networks erreichen in vielen Themenbereichen bemerkenswerte Ergebnisse. GNNs könnten in der Zukunft die Medizin verändern, aufgrund der Vorhersage von Knoten und der Klassifikation von kompletten Graphen. Anhand dieser könnten Krankheiten deutlich besser vorhergesagt werden, als mit den aktuell verwendeten Methoden. [3] [8] [18] [20] Zudem ist das Problem der Inkubationszeit nicht mehr ausschlaggebend, da dies aktuell für viele Probleme gesogt hatte. Diese Erkenntnis kann vor allem aufgrund der von GNNs erzielten Accuracy gesagt werden, wie zum Beispiel in der neu entwickelten GraphCovidNet Methode, welche eine Accuracy von 100 erzielt. [8] Zudem könnten

Krankheiten besser behandelt werden. Dies geschieht anhand der Klassifikation von Graphen. Moleküle können klassifiziert und bestimmt werden, ob diese bestimmte Eigenschaften erweisen, um bei einer bestimmten Krankheit anzuschlagen oder Wirkung zu zeigen.

9. REFERENZEN/QUELLEN

- [1] Point cloud representation, Lars Linsen, Universität Karlsruhe Germany
- [2] Point-GNN: Graph Neural Network for 3D Object Detection in a Point Cloud
- [3] MGNN: A Multimodal Graph Neural Network for Predicting the Survival of Cancer Patients
- [4] <https://www.youtube.com/watch?v=zyBsVxTVdY>
- [5] The Graph Neural Network Model, Franco Scarselli, Marco Gori, IEEE, Ah Chung Tsoi, Markus Hagenbuchner, Member, IEEE, and Gabriele Monfardini
- [6] A RECURRENT GRAPH NEURAL NETWORK FOR MULTI-RELATIONAL DATA, Vassilis N. Ioannidis, Antonio G. Marques†, Georgios B. Giannakis
- [7] Graph neural networks: A review of methods and applications, Jie Zhou a, Ganqu Cui, Shengding Hu, Zhengyan Zhang, Cheng Yang, Zhiyuan Liu, Lifeng Wang, Changcheng Li, Maosong Sun
- [8] GraphCovidNet: A graph neural network based model for detecting COVID-19 from CT scans and X-rays of chest, Pritam Saha, Debadyuti Mukherjee, Pawan Kumar Singh, Ali Ahmadian, Massimiliano Ferrara, Ram Sarkar
- [9] Spatial Graph Convolutional Networks, Tomasz Danel, Przemysław Spurek, Jacek Tabor, Marek Śmieja, Łukasz Struski, Agnieszka Słowik, Łukasz Maziarka
- [10] Understanding Spectral Graph Neural Network, Xinye Chen
- [11] Machine Learning in Radiation Oncology, Issam El Naqa, Ruijiang Li, Martin J. Murphy
- [12] Deep Recurrent Graph Neural Networks, Luca Pasa, Nicolò Navarin, Alessandro Sperduti
- [13] Miles F Jefferson, Neil Pendleton, Sam B Lucas, and Michael A Horan. Comparison of a genetic algorithm neural network with logistic regression for predicting outcome after surgery for patients with nonsmall cell lung carcinoma. Cancer: Interdisciplinary International Journal of the American Cancer Society, 79(7):1338– 1342, 1997
- [14] Cuong Nguyen, Yong Wang, and Ha Nam Nguyen. Random forest classifier combined with feature selection for breast cancer diagnosis and prognostic. Journal of Biomedical Science and Engineering, 6:551–560, 2013
- [15] Xiaoyi Xu, Ya Zhang, Liang Zou, Minghui Wang, and Ao Li. A gene signature for breast cancer prognosis using support vector machine. In International Conference on Biomedical Engineering and Informatics, pages 928–931, 2012
- [16] Dongdong Sun, Minghui Wang, and Ao Li. A multimodal deep neural network for human breast cancer prognosis prediction by integrating multi-dimensional data. TCBB, 16(3):841–850, 2018
- [17] https://www.rki.de/DE/Content/InfAZ/N/Neuartiges_Coronavirus/Steckbrief.html
- [18] Graph Neural Network-Based Diagnosis Prediction, Yang Li, Buyue Qian, Xianli Zhang, Hui Liu
- [19] Every Document Owns Its Structure: Inductive Text Classification via Graph Neural Networks, Yufeng Zhang, Xueli Yu1, Zeyu Cui, Shu Wu1, Zhongzhen Wen, Liang Wang
- [20] Classification of Cancer Types Using Graph Convolutional

- tional Neural Networks, Ricardo Ramirez, Yu-Chiao Chiu, Allen Hererra, Milad Mostavi, Joshua Ramirez, Yidong Chen, Yufei Huang, Yu-Fang Jin
- [21] Learning Graph Distances with Message Passing Neural Networks, Riba et al., 2018
- [22] Graph Matching Networks for Learning the Similarity of Graph Structured Objects, Li et al., 2019b
- [23] Attributed graph clustering via adaptive graph convolution, Zhang et al., 2019c
- [24] Hierarchical graph representation learning with differentiable pooling, Ying et al., 2018b
- [25] Graph Clustering with Graph Neural Networks, Tsitsulin et al., 2020
- [26] Interaction networks for learning about objects, relations and physics, Battaglia et al., 2016
- [27] Learning multiagent communication with backpropagation, Sukhbaatar Fergus et al., 2016
- [28] Visual interaction networks: learning physics simulator from video, Watters et al., 2017
- [29] Vain: attentional multi-agent predictive modeling, Hoshen, 2017
- [30] Neural relational inference for interacting systems, Kipf et al., 2018
- [31] Graph networks as learnable physics engines for inference and control, Sanchez et al., 2018
- [32] Convolutional networks on graphs for learning molecular fingerprints, Duvenaud et al., 2015
- [33] Graph transformation policy network for chemical reaction prediction, Do et al., 2019
- [34] Protein interface prediction using graph convolutional networks, Fout et al., 2017
- [35] Modeling polypharmacy side effects with graph convolutional networks, Zitnik et al., 2018
- [36] Hybrid Approach of Relation Network and Localized Graph Convolutional Filtering for Breast Cancer Subtype Classification, Rhee et al., 2018
- [37] Knowledge transfer for out-of-knowledge-base entities: a graph neural network approach, Hamaguchi et al., 2017
- [38] Modeling relational data with graph convolutional networks, Schlichtkrull et al., 2018
- [39] End-to-end structure-aware convolutional networks for knowledge base completion, Shang et al., 2019
- [40] Cross-lingual knowledge graph alignment via graph convolutional networks, Wang et al., 2018b
- [41] Oag: toward linking large-scale heterogeneous entity graphs, Zhang et al., 2019d
- [42] Cross-lingual knowledge graph alignment via graph matching neural network, Xu et al., 2019c
- [43] Netgan: generating graphs via random walks, Shchur et al., 2018b
- [44] Revised note on learning quadratic assignment with graph neural networks, Nowak et al., 2018
- [45] Constrained generation of semantically valid graphs via regularizing variational autoencoders, Ma et al., 2018
- [46] Graph convolutional neural networks for web-scale recommender systems, You et al., 2018a
- [47] MolGAN: an Implicit Generative Model for Small Molecular Graphs. ICML 2018 Workshop on Theoretical Foundations and Applications of Deep Generative Models, De Cao and Kipf, 2018
- [48] Learning Deep Generative Models of Graphs, Li et al., 2018d
- [49] Graphaf: a Flow-Based Autoregressive Model for Molecular Graph Generation, Shi et al., 2020
- [50] Graph normalizing flows, Liu et al., 2019
- [51] Graphite: iterative generative modeling of graphs, Grover et al., 2019
- [52] Learning combinatorial optimization algorithms over graphs, Khalil et al., 2017
- [53] Revised note on learning quadratic assignment with graph neural networks, Nowak et al., 2018
- [54] Combinatorial optimization with graph convolutional networks and guided tree search, Li et al., 2018e
- [55] Attention, learn to solve routing problems, Kool et al., 2019
- [56] Neural Combinatorial Optimization with Reinforcement Learning, Bello et al., 2017
- [57] Pointer networks, Vinyals et al., 2015b
- [58] Reinforcement Learning: an Introduction, Sutton and Barto, 2018
- [59] Discriminative embeddings of latent variable models for structured data, Dai et al., 2016
- [60] Exact combinatorial optimization with graph convolutional neural networks, Gasse et al., 2019
- [61] Learning sparse nonparametric dags, Zheng et al., 2020a
- [62] Learning a SAT solver from single-bit supervision, Selsam et al., 2019
- [63] Approximation ratios of graph neural networks for combinatorial problems, Sato et al., 2019
- [64] Traffic Graph Convolutional Recurrent Neural Network: A Deep Learning Framework for Network-Scale Traffic Learning and Forecasting, Cui et al., 2018b
- [65] Spatio-temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting, Yu et al., 2018
- [66] A graph multi-attention network for traffic prediction, Zheng et al., 2020b
- [67] Attention based spatial-temporal graph convolutional networks for traffic flow forecasting, Guo et al., 2019
- [68] Graph convolutional matrix completion, van den Berg et al., 2017
- [69] Graph convolutional neural networks for web-scale recommender systems, Ying et al., 2018a
- [70] Dual graph attention networks for deep latent representation of multifaceted social effects in recommender systems, Wu et al., 2019c
- [71] Graph neural networks for social recommendation, Fan et al., 2019
- [72] Exploring Graph Neural Networks for Stock Market Predictions with Rolling Window Analysis, Matsunga et al., 2019
- [73] Using external knowledge for financial event prediction based on graph neural networks, Yang et al., 2019
- [74] Incorporating corporation relationship via graph convolutional neural networks for stock price prediction, Chen et al., 2018c
- [75] Modeling the stock relation with graph network for overnight stock movement prediction, Li et al., 2020
- [76] Hats: A Hierarchical Graph Attention Network for Stock Movement, Kim et al., 2019
- [77] Unveiling the potential of graph neural networks for network modeling and optimization in sdn, Rusek et al., 2019
- [78] A graph-to-sequence model for amr-to text generation, Song et al., 2018a

- [79] Graph-to-sequence learning using gated graph neural networks, Beck et al., 2018
- [80] Large-scale hierarchical text classification with recursively regularized deep graph-cnn, Peng et al., 2018
- [81] Graph convolutional networks for text classification, Yao et al., 2019
- [82] Sentence-state lstm for text representation, Zhang et al., 2018d
- [83] Improved semantic representations from tree structured long short-term memory networks, Tai et al., 2015
- [84] Sentence-state lstm for text representation, Zhang et al., 2018d
- [85] Encoding sentences with graph convolutional networks for semantic role labeling, Marcheggiani and Titov, 2017
- [86] Graph convolutional encoders for syntax-aware neural machine translation, Bastings et al., 2017
- [87] Exploiting semantics in neural machine translation with graph convolutional networks, Marcheggiani et al., 2018
- [88] Graph-to-sequence learning using gated graph neural networks, Beck et al., 2018
- [89] End-to-end relation extraction using lstms on sequences and tree structures, Miwa and Bansal, 2016
- [90] Cross-sentence n-ary relation extraction with graph lstms, Peng et al., 2017
- [91] N-ary relation extraction using graph state lstm, Song et al., 2018b
- [92] Graph convolution over pruned dependency trees improves relation extraction, Zhang et al., 2018f
- [93] Graph convolutional networks with argument-aware pooling for event detection, Nguyen and Grishman, 2018
- [94] Jointly multiple events extraction via attention-based graph information aggregation, Liu et al., 2018
- [95] Gear: graph-based evidence aggregating and reasoning for fact verification, Zhou et al., 2019
- [96] Fine-grained fact verification with kernel graph attention network, Liu et al., 2020
- [97] Reasoning over semantic-level graph for fact checking, Zhong et al., 2020
- [98] Exploring Graph Structured Passage Representation for Multi-Hop Reading Comprehension with Graph Neural Networks, Song et al., 2018c
- [99] Question answering by reasoning across documents with graph convolutional networks, De Cao et al., 2019
- [100] Dynamically fused graph network for multi-hop reasoning, Qiu et al., 2019
- [101] Multi-hop reading comprehension across multiple documents by reasoning over heterogeneous graphs, Tu et al., 2019
- [102] Cognitive graph for multi-hop reading comprehension at scale, Ding et al., 2019
- [103] A simple neural network module for relational reasoning, Santoro et al., 2017
- [104] Recurrent relational networks, Palm et al., 2018
- [105] Interaction networks for learning about objects, relations and physics, Battaglia et al., 2016
- [106] Deep reasoning with knowledge graph for social relationship understanding, Wang et al., 2018c
- [107] Few-shot learning with graph neural networks, Garcia and Bruna, 2018
- [108] Zero-shot recognition via semantic embeddings and knowledge graphs, Wang et al., 2018d
- [109] Multi-label zero-shot learning with structured knowledge graphs, Lee et al., 2018b
- [110] Rethinking Knowledge Graph Propagation for Zero-Shot Learning, Kampffmeyer et al., 2019
- [111] The more you know: using knowledge graphs for image classification, Marino et al., 2017
- [112] Graph-structured representations for visual question answering, Teney et al., 2017
- [113] Deep reasoning with knowledge graph for social relationship understanding, Wang et al., 2018c
- [114] Out of the box: reasoning with graph convolution nets for factual visual question answering, Narasimhan et al., 2018
- [115] Relation networks for object detection, Hu et al., 2018
- [116] Learning region features for object detection, Gu et al., 2018
- [117] Learning human-object interactions by graph parsing neural networks, Qi et al., 2018
- [118] Structural-rnn: deep learning on spatio-temporal graphs, Jain et al., 2016
- [119] Iterative visual reasoning beyond convolutions, Chen et al., 2018d
- [120] Semantic object parsing with graph lstm, Liang et al., 2016
- [121] Interpretable structure evolving lstm, Liang et al., 2017
- [122] Large-scale point cloud semantic segmentation with superpoint graphs, Ladriau and Simonovsky, 2018
- [123] Dynamic Graph Cnn for Learning on Point Clouds, Wang et al., 2018e
- [124] 3d graph neural networks for rgb-d semantic segmentation, Qi et al., 2017b
- [125] Learning to represent programs with graphs, Allamanis et al., 2018
- [126] Gated graph sequence neural networks, Li et al., 2016
- [127] Hierarchical graph representation learning with differentiable pooling, You et al., 2018b
- [128] Drug-Disease Graph: Predicting Adverse Drug Reaction Signals via Graph Neural Network with Clinical Data, Kwak et al., 2021
- [129] Convolutional neural networks: an overview and application in radiology, Yamashita et al., 2018
- [130] Applications of Deep Convolutional Neural Network in Computer Vision, Hongtao et al.
- [131] Convolutional neural network: a review of models, methodologies and applications to object detection, Dhillon et al., 2019
- [132] A Comprehensive Survey on Graph Neural Networks, Wu et al., 2021
- [133] What is Machine Learning?, El Naqa et al.
- [134] SuperGlue: Learning Feature Matching with Graph Neural Networks, Sarlin et al., 2020
- [135] End-to-end learning for point cloud based 3d object detection, Zhou et al., 2018
- [136] Second: Sparsely embedded convolutional detection, Yan et al., 2018
- [137] Pointpillars: Fast encoders for object detection from point clouds, Lang et al., 2019
- [138] Pointnet++: 3d object proposal generation and detection from point cloud, Shi et al., 2019
- [139] Std: Sparse-to-dense 3d object detector for point cloud, Yang et al., 2019
- [140] SuperPoint: Self-supervised interest point detection and description, DeTone et al., 2018

- [141] ScanNet: Richly-annotated 3D reconstructions of indoor scenes, Dai et al., 2017
- [142] LF-Net: Learning local features from images, Ono et al., 2018
- [143] Structure-from-motion revisited, Schöneberger and Frahm, 2016
- [144] Pixelwise view selection for unstructured multi-view stereo, Schönberger et al., 2016
- [145] <https://image-matching-workshop.github.io/>, Phototourism Challenge, CVPR 2019 Image Matching Workshop
- [146] YFCC100M:The new data in multimedia research. Communications of the ACM, Thomee et al., 2016
- [147] SARS-CoV-2 CT-scan dataset: A large dataset of real patients CT scans for SARS-CoV-2 identification, Soares et al., 2020
- [148] Covid-CT-dataset: A CT scan dataset about COVID-19, Yang et al., 2020
- [149] Diffusion convolutional recurrent neural network: Data-driven traffic forecasting, Li et al., 2018
- [150] Spatial temporal graph convolutional networks for skeleton-based action recognition, Yan et al., 2018