


UNIVERSITÄT AUGSBURG
INSTITUT FÜR INFORMATIK



Forschungsarbeit im Studiengang Informatik

**Twitter Analyse der Fußball
Weltmeisterschaft 2014**

vorgelegt von

Tobias Quirin Artz, Onurcan Ünsal

Gutachter: Prof. Dr. Peter Fischer
Zweitgutachter: Johannes Kastner
Betreuer: Betreuer
Datum: 23. September 2021

Inhaltsverzeichnis

Abbildungsverzeichnis	iii
Tabellenverzeichnis	iv
1 Abstract	1
2 Einleitung	1
3 Geschichte	1
4 Weltmeisterschaft	1
4.1 Geschichte der Weltmeisterschaft	1
4.2 Fussball Weltmeisterschaft 2014	1
5 Tools	1
5.1 Python	1
5.2 Datensätze	1
5.3 Spark	1
5.4 Vorgehensweise	2
5.5 Laufzeitanalyse	2
6 NLP	1
6.1 Natural Language Processing (NLP)	1
6.1.1 <i>Symbolischer</i> Ansatz	1
6.1.2 <i>Statischer</i> Ansatz	2
6.1.3 <i>Konnektionistischer</i> Ansatz	2
6.1.4 <i>Hybrider</i> Ansatz	2
6.2 Hauptaufgaben in Natural Language Processings	2
6.3 Analyse des Sentiments	2
6.3.1 Polarity	3
6.3.2 Subjectivity	3
6.3.3 Afinn	3
6.3.4 N-Grams	4
6.3.4.1 Polarity vs. 2-Gram	4
6.3.4.2 Polarity vs. 3-Gram	4
6.3.4.3 Polarity vs. 4-Gram	5
6.3.4.4 Polarity vs. 5-Gram	5
6.4 Grund für die Nicht-Verwendung der Analyse von Emojis	7

7	Erwartungen	1
7.1	Hypothesen	1
8	Auswertung	1
8.1	Städte, die am meisten getweetet haben	1
8.2	Länder, die am meisten getweetet haben	2
8.3	Sprachen, die am meisten getweetet haben	3
8.4	Meisten Tweets in Abhängigkeit der Zeitzone	3
8.5	Am meisten verwendeten Hashtags in/während der Weltmeisterschaft	4
8.6	Am meisten getweeteten Tweets während der Weltmeisterschaft 2014	7
8.7	Verteilung der Polarity aller Tweets der Weltmeisterschaft 2014	9
8.8	Alle Tweets mit Erwähnungen des Schiedsrichters	10
8.8.1	Je mehr Duplikate, desto mehr Sentiment?	11
8.9	Alle Tweets über den Schiedsrichter: Vergleich mit und ohne Duplikate	12
8.9.1	Verteilung der Polarity von Tweets mit Schiedsrichterwähnungen	13
9	Zusammenfassung	1
A	Anhang	2
A.1	Referenzen	2
B	Inhalt der CD	4
C	Erklärung	5

Abbildungsverzeichnis

3.1	Die beliebtesten Sportarten auf der Welt [18]	2
4.1	Aufteilung der Gruppen für die WM 2014 nach dem Auslosen	2
5.1	Caption	3
6.1	NLP-Pipeline	3
6.2	Vergleich zwischen der Polarity und 2-Gram	5
6.3	Vergleich zwischen der Polarity und 3-Gram	6
6.4	Vergleich zwischen der Polarity und 4-Gram	6
6.5	Vergleich zwischen der Polarity und 5-Gram	7
6.6	Die am meisten analysierten Emojis	8
8.1	Verteilung der Tweets in Bezug auf die Städte	2
8.2	Verteilung der Tweets in Bezug auf die Länder	3
8.3	Verteilung der Tweets in Bezug auf die Sprache	4
8.4	Verteilung der Tweets in Bezug auf die Zeitzone	5
8.5	Anzahl der Tweets, gruppiert nach den Zeitzonen	5
8.6	Die am häufigsten verwendeten Hashtags	6
8.7	Die Anzahl der Top 10 Tweets	7
8.8	Die Polarity der Top 10 Tweets	8
8.9	Der Augenblick an dem Luis Suarez den italienischen Spieler Chellini biss [9]	9
8.10	Verteilung der Polarity aller Tweets während aller Tweets	10
8.11	Verteilung der Polarity und Subjectivity von allen Tweets	11
8.12	Alle Tweets über den Schiedsrichter: Vergleich mit und ohne Duplikate in Bezug auf die Polarity	13
8.13	Verteilung der Polarity von Tweets, die Schiedsrichtererwähnungen enthalten	14
8.14	Clustering der Polarity und Subjectivity der Tweets des Schiedsrichters	14

Tabellenverzeichnis

1 Abstract

Twitter zählt zu den bekanntesten sozialen Netzwerken, die es gibt. In dieser Forschungsarbeit geht es um die Analyse der Tweets, die während der Fußball Weltmeisterschaft 2014 getweetet wurden. Dafür wurden die, von der Universität Augsburg zur Verfügung gestellten, Daten mithilfe von Spark ausgewertet. Darunter fällt die Analyse der Tweets über Schiedsrichter, die Hashtaganalyse, sowie die Auswertung über den Ursprung der Nachrichten. Außerdem wird in dieser Arbeit untersucht, welche Hilfsmittel zu der Analyse beitragen und welche nicht ausreichend sind aufgrund einer zu schlechten Performance oder zu wenig trainierten Trainingssätzen. Es zeigt sich, dass die NGram Analyse, sowie die Emojie Analyse unzureichend sind. Des Weiteren zeigt sich, dass überwiegend englische Tweets gepostet werden und die Herkunft der Tweets aus Amerika sind.

2 Einleitung

Es gibt viele Sportarten auf der Welt. Zu den beliebtesten zählen Baseball, American Football, Tennis, Tischtennis, Basketball und Cricket. Jedoch ist Fussball mit 3,5 Milliarden Unterstützern die beliebteste Sportart auf der Welt. Aber woran liegt das? Zum einen liegt das daran, dass Fußball ein sehr einfach zu verstehendes und unterhaltsames Spiel ist. Hinzu kommt, dass Fussball derart Aufsehen erregt hat, dass Weltmeisterschaften (WM) ausgetragen werden. Alle vier Jahre messen sich die besten Teams jedes Landes auf der Welt, um sich für die Weltmeisterschaft qualifizieren zu können. Die letzte WM, also die WM 2018, wurde von 3,572 Milliarden Menschen verfolgt. Das heißt, dass fast die Hälfte der Weltbevölkerung (Stand 2018: 7,63 Mrd.) dieses Ereignisse verfolgt haben. Die Weltermeyerschaft ist für jeden ein wichtiges Ereignis, da Menschen, die normalerweise kein Fussball verfolgen, aufgrund ihres Nationalstolzes mit ihrem Land mitfiebern und sogar in Social Media die WM infiltriert wird. Dies führt meist zu vielen Emotionen, sodass die Menschen ihre Emotionen auf sozialen Netzwerken wiedergeben wollen. Der dadurch entstehende massive Informationsaustausch beschränkt sich aber nicht nur auf ein Land, sondern ist weltweit erreichbar. Zu diesen sozialen Netzwerken zählen unter anderem Instagram, Facebook und Twitter. In der vorliegenden Forschungsarbeit befassen wir uns mit Twitternachrichten, die zu Zeiten der Fußball Weltmeisterschaft 2014 getweetet wurden. Twitter hat 330 Millionen aktive Nutzer und zählt somit zu den größeren sozialen Netzwerken. Twitter wird in vielen Fällen verwendet, wenn ein Nutzer seine Meinung zu etwas abgeben möchte. Aber was hat es mit den Nachrichten auf sich, zu der jede Person befähigt ist. Handelt es sich dabei um unterhaltende oder gar sinnvolle Nachrichten oder sind es Kommentare, die nur Exklamationen der Gedanken sind, die ein Mensch, für welchen Zweck auch immer, der Welt mitteilen möchte. Das ist der ideale Fall für unsere Analyse, denn viele Nutzer möchten sich nach, während oder vor dem Spiel äußern egal in welcher Hinsicht und nutzen Twitter, um so viele Leser wie möglich zu erreichen. In der vorliegenden Analyse haben wir 47.400.000 Tweets analysiert und ausgewertet, um zu untersuchen, welche Art von Tweets primär gepostet wurden.

3 Geschichte

Fußball ist eine Sportart, die schon über 2000 Jahre alt ist und sich im Laufe der Zeit zu einer der beliebtesten Sportarten entwickelt hat. Aktuell zählt Fussball zu der beliebtesten Sportart auf der ganzen Welt, siehe Abbildung 3.1.

Fußball gab es zwar schon vor über 2000 Jahren, wurde aber nicht dokumentiert und geriet deswegen in Vergessenheit. Die Regeln des Fußballs wurden erstmalig 1848 in England festgehalten. Im Laufe der Jahre hat sich viel in Fußball verändert, zwar existieren noch die damals eingeführten Regeln, aber diese werden mithilfe von technischen Mitteln überwacht. Um den Regeln gerecht zu werden, werden Techniken wie der Videobeweis oder Replays mittels Kameras verwendet. Dadurch können beispielsweise Fehlentscheidungen oder Fouls präzise entschieden werden. Hinzu kommt, dass mittels modernen Kameras die Fußballspiele in höheren Klassen aufgezeichnet werden, um diese zu übertragen und dadurch für jeden zugänglich zu machen. Der Grund für diese Expansion ist, dass der Fußball an Aufsehen und Prestige gewonnen hat. Außerdem ist Fußball nicht nur in höheren Klassen beliebt, sondern in jeder Altersgruppe und es finden deshalb jährlich nationale Turniere statt, sowohl in unteren, als auch in oberen Klassen. Zudem werden Dopingtests durchgeführt, um Handycaps zu verhindern. Dadurch können faire Spiele stattfinden, bei denen keine Benachteiligungen zustande kommen.

Top 10 der beliebtesten Sportarten




Abbildung 3.1: Die beliebtesten Sportarten auf der Welt [18]

4 Weltmeisterschaft

4.1 Geschichte der Weltmeisterschaft

Die Geschichte der Weltmeisterschaft begann 1863 durch die Gründung der englischen Football Association (FA) in London. Das erste Spiel nach den Regeln der FA fand am 9. Januar 1864 statt. Das erste Spiel zwischen nationalen Mannschaften war das Spiel von Schottland gegen England. Am 21. Mai 1904 wurde durch Robert Guerin und Carl Anton Wilhelm Hirschmann die FIFA (Fédération Internationale de Football Association) in Paris gegründet. 26 Jahre später fand die erste Fußball-Weltmeisterschaft in Uruguay statt. Um den Austragungsort der Weltmeisterschaft zu entscheiden, gibt es ein Vergabeverfahren des Exekutiv-Ausschusses der FIFA. Im Jahr 2000 wurde für das Vergabeverfahren ein sogenanntes Rotationsverfahren eingeführt. Demnach werden Weltmeisterschaften ab 2010 im regelmäßigen Wechsel zwischen den sechs Kontinentalverbänden stattfinden, jedoch wurde das Verfahren kurze Zeit später im Jahr 2007 abgeschafft. Dabei wurden Kontinentalverbände ausgeschlossen, in welchen die letzten beiden Weltmeisterschaften stattgefunden haben. Demnach hieß es für die Weltmeisterschaft 2018, dass Länder aus dem Südamerikanischen Fußballverband und Afrikanischen Fußballverband als Gastgeber ausgeschlossen worden sind. [1]

4.2 Fußball Weltmeisterschaft 2014

Der Südamerikanische Fußballverband als Gastgeber wurde 2018 deswegen ausgeschlossen, weil die Fußball Weltmeisterschaft 2014 in Brasilien statt fand. Diese begann am 12. Juni 2014 in Sao Paulo. An der Weltmeisterschaft waren 32 Nationen aus der ganzen Welt beteiligt. In der WM 2014 gab es 64 Spiele. Dies berechnet sich aus der Multiplikation von der Anzahl an den Teilnehmenden Nationen mit dem Faktor Zwei, da es zu jedem Spiel eine Hin- und Rückspiel gibt. Die wurden 2013 ausgelost und in ihre Gruppen eingeteilt. Die Gruppen der Weltmeisterschaft bilden sich aus 8 Gruppen mit jeweils 4 Mannschaften. Die Verteilung der Mannschaften in die Gruppen ist in Abbildung 4.1 zu sehen.

Das Finale der Weltmeisterschaft bestand aus dem Zusammentreffen der beiden Nationalmannschaften Deutschland und Argentinien. Deutschland entschied das Spiel für sich mit einem Endergebnis von 1:0. Das Finale brach in Deutschland einen neuen Rekord. 34,65 Millionen Zuschauer verfolgten das Spiel vor dem Bildschirm. Hinzu kommt, dass Personen, die an dem Public Viewing auf öffentlichen Plätzen teilgenommen haben, nicht eingerechnet sind.

Die Sportveranstaltung sorgte auch im Netz für Aufsehen. Nach Abpfiff des Finales verbuchte Twitter 618 725 Tweets pro Minute. Jedoch ist das Halbfinale zwischen Brasilien und Argentinien Spitzenreiter, denn Twitter meldete einen Rekord ab 60 Minuten vor dem Spiel bis 30 Minuten nach dem Abpfiff mit 35,6 Millionen Tweets.

Gruppe A	Gruppe B	Gruppe C	Gruppe D
Brasilien	Spanien	Kolumbien	Uruguay
Kroatien	Niederlande	Griechenland	Costa Rica
Mexiko	Chile	Elfenbeinküste	England
Kamerun	Australien	Japan	Italien

Gruppe E	Gruppe F	Gruppe G	Gruppe H
Schweiz	Argentinien	Deutschland	Belgien
Ecuador	Bosnien und Herzegowina	Portugal	Algerien
Frankreich	Iran	Ghana	Russland
Honduras	Nigeria	USA	Südkorea

Abbildung 4.1: Aufteilung der Gruppen für die WM 2014 nach dem Auslosen

Facebook registrierte 280 Millionen Interaktionen im Zusammenhang mit dem WM Finale.
[17]

5 Tools

5.1 Python

Für die Durchführung der Analyse wurde die Programmiersprache Python verwendet. Die Programmiersprache wurde von Guido van Rossum entwickelt. Python ist in den letzten Jahren immer beliebter geworden. Die Design-Philosophie des niederländischen Entwicklers legt den Schwerpunkt auf die Lesbarkeit des Codes und verwendet deshalb eine deutliche Einrückung. [1]

Python unterstützt mehrere Programmierparadigmen, darunter die strukturierte, objektorientierte und funktionale Programmierung.

Guido van Rossum begann gegen Ende der 1980er Jahre mit der Arbeit an Python, welche als Nachfolger der ABC-Programmiersprache und veröffentlichte diese erstmals in 1991 als Python 0.9.0. [2] Python 2.0 wurde einige Zeit später im Jahr 2000 veröffentlicht und führte neue Funktionen ein, wie zum Beispiel das Listenverständnis und ein Garbage-Collection-System mit Referenzzählung. Python 3.0 wurde 2008 veröffentlicht und war eine größere Überarbeitung der Sprache, welche nicht vollständig abwärtskompatibel ist. Python zählt aktuell zu den beliebtesten Programmiersprachen. [3] [4] [5] [6]

5.2 Datensätze

Die für die Analyse verwendeten Datensätze wurden von der Universität Augsburg zur Verfügung gestellt. Die Datensätze beinhalten 47,4 Millionen Tweets, die während der Weltmeisterschaft 2014 aufgezeichnet wurden. Die Tweets wurden in mehrere Samples eingeteilt und wurden als JSON-Datei gespeichert. Dadurch wurde jeder Tweet einheitlich strukturiert, sodass auf diese präzise Informationen über User, die die Tweets veröffentlicht haben, zugegriffen werden kann. Die vorliegenden JSON-Dateien, enthalten mehrere wichtige Daten, welche bei unserer Sentimentanalyse angewendet wurden.

5.3 Spark

Big-Data Analyse ist eine der aktivsten Forschungsbereiche mit vielen Herausforderungen und dem Bedarf an Innovation, die ein breites Spektrum von Branchen betreffen. Um die rechnerischen Anforderungen der Massendatenanalyse zu erfüllen, ist ein effizientes Framework essentiell für die Entwicklung, Implementierung und Verwaltung der erforderlichen Pipelines und Algorithmen. [8] Aufgrund der Größe unserer Datensätze haben wir für die Analyse der Daten Apache Spark verwendet. Spark ist ein Open-Source System, das für Big Data Analysen

verwendet wird. Spark ist in der Lage, Aufgaben wesentlich schneller fertig zu stellen als frühere Big-Data-Tools, aufgrund von des In-Memory Caching und der optimierten Ausführung von Abfragen. Spark bietet Entwicklungs-APIs in Python, Java, Scala und R. Für unsere Analyse verwenden wir die Entwicklungs-API in Python. Zusätzlich zum Hauptcomputing-Framework stellt Spark maschinelles Lernen, SQL, Graphanalyse und Streaming-Bibliotheken zur Verfügung. [7]

5.4 Vorgehensweise

Zunächst haben wir uns mit den, zur Verfügung gestellten, Json-Dateien vertraut gemacht, indem wir die Struktur der Datei untersucht haben. Daraufhin haben wir uns mit Spark beschäftigt. Dazu haben wir eine Json-Datei als Input verwendet und ausprobiert, wie man auf die Texte und Zahlen der jeweiligen Kategorien zugreifen kann. Die Ergebnisse wurden zu Beginn auf der Kommandozeile ausgegeben, um zu überprüfen, ob wir auf die gewünschte Kategorie zugreifen konnten. Anschließend haben wir damit begonnen, die Daten als CSV Dateien festzuhalten. Mithilfe von SPARK konnten wir nicht nur Texte abspeichern, sondern auch die Vorkommen der gewünschten Attribute zählen. Das Zählen wurde durch die SPARK Funktion *count* ermöglicht. Dadurch konnten wir die resultierenden Daten, die mithilfe von Spark erzeugt wurden, abspeichern. Die gespeicherten CSV-Dateien wurden benutzt, um zum einen Preprocessing auf den Texten anzuwenden. Dazu haben wir die Bibliothek *preprocessor* verwendet, die über die Funktion *clean* alle unerwünschten Vorkommen wie Hashtags, Sonderzeichen, Links, E-Mail Adressen, Emojis, usw. im jeweiligen Text entfernt. Das Preprocessing haben wir gebraucht, um die Daten dann auf die Polarität zu untersuchen. Die Polarität konnten wir durch die Bibliothek *textblob* errechnen, die über die Methode *polarity* verfügt. Außerdem haben wir untersucht, ob die Methoden, wie *clean* oder *polarity* auch das machen, was wir erzielen wollen. Dazu haben wir sowohl selbst erstellte Texte, als auch Texte aus den JSON-Dateien benutzt und uns ausgeben lassen. Dadurch konnten wir dann selbst überprüfen, ob die Ausgaben bzw. die Werte tatsächlich dem entsprechen, was die Ausgabe der jeweiligen Methoden versprochen. Zum Anderen wurden die CSV-Dateien verwendet, um Graphen und Diagramme zu erstellen. So haben wir beispielsweise die Histogramme erstellen können, indem wir die Bibliothek *matplotlib* verwendet haben. Außerdem konnten wir die, von *count* erzeugten Zahlen, in den CSV Dateien abrufen und per Google Docs Diagrammen diese Werte verbildlichen.

5.5 Laufzeitanalyse

Die Durchführung der Analyse hat aufgrund folgender Aspekte Zeit in Anspruch genommen. Zuerst haben wir die Daten, die von der Universität als *.json*-Dateien zur Verfügung gestellt wurden und eine Größe von circa 161 Gigabyte haben, analysiert, um zu erkennen, wie diese aufgebaut sind und wie wir auf diese zugreifen können. Das hat eine geringe Laufzeit, da wir aufgrund des Formats der *.json*-Datei das Attribut erkennen und somit leicht ausgeben konnten. Daraufhin haben wir uns mit *spark* vertraut gemacht, indem wir die SQL Anfragen auf einen der heruntergeladenen Datensätze angewandt haben. Daraufhin haben wir SQL-Anfragen erstellt und Ausgaben ausgeben lassen, um zu sehen, ob wir das gewollte Ergebnis

Verteilung der Bearbeitungszeit




Abbildung 5.1: Caption

erzielen. Die Laufzeit dieser Anfrage hing von der Größe der Eingabedaten ab. Das Vorgehen konnten wir optimieren, indem wir die *select* Anweisung von Spark verwendet haben, die es uns ermöglicht hat, auf SQL Anfragen zu verzichten. Diese haben pro Anfrage im Durchschnitt zwischen zwei und drei Stunden gebraucht. Nachdem wir uns mit der Daten vertraut gemacht haben, mussten wir diese bereinigen. Dieser Schritt war sehr wichtig, da in vielen Tweets Hashtags, Links und Markierungen waren, die das Sentiment verfälschen könnten. Für das Bereinigen der Tweets haben wir die Bibliothek *tweet-preprocessor* verwendet. Die Laufzeit der *clean* Funktion war sehr gering und die übergebenen Tweets waren in relativ kurzer Zeit bereinigt. Die Laufzeit der Bereinigung aller Tweets hat ungefähr 30 Minuten in Anspruch genommen. Nach der Reinigung der Daten haben wir die Daten als *.csv-Dateien* abgespeichert. Das Speichern hat vergleichsweise lange gedauert. Das Erstellen von *.csv-Dateien* hat pro Datei zwischen drei und vier Stunden gebraucht. Dies hat die meiste Zeit in Anspruch genommen, da es sich bei unseren Datensätzen um eine Gesamtanzahl von 47,4 Millionen Tweets handelt. Nachdem wir uns mit allen Werkzeugen, wie *spark*, *preprocessing* und Speichern als *.csv* Datei vertraut gemacht haben, haben wir angefangen, die Anfragen auf alle Datensätze laufen zu lassen. Zuletzt haben wir uns damit beschäftigt Graphen zu erstellen, die mithilfe der Ergebnisse zustande gekommen sind. Dies hat am wenigsten Zeit in Anspruch genommen. Diese haben im Durchschnitt zehn Minuten gedauert, da wir die Ergebnisse als *.csv-Dateien* abgespeichert haben und diese dadurch gut verarbeiten konnten.

6 NLP

6.1 Natural Language Processing (NLP)

Es gibt Begriffe, die sich zwar ähneln, sich aber dennoch unterscheiden. Es gibt das Natural Language Processing (NLP), das sich mit der Verarbeitung der natürlichen Sprache befasst. Ein weiterer Begriff, der auftaucht, ist Natural Language Understanding (NLU). Dieser beschäftigt sich mit dem Verstehen der natürlichen Sprache. Der letzte Ausdruck ist die Natural Language Generation (NLG). Dieser beschäftigt sich mit der Erzeugung von natürlicher Sprache. [15]

Natural Language Processing ist ein Forschungs- und Anwendungsgebiet, das sich mit der Frage beschäftigt, wie Computer eingesetzt werden, um Texte oder Sprache in natürlicher Form zu verstehen und damit zweckdienliche Arbeiten anzustellen. Das Ziel ist Erkenntnisse darüber zu gewinnen, wie Menschen die Sprache verstehen und verwenden, damit geeignete Werkzeuge und Techniken entwickelt werden können. Anhand dieser Techniken soll es Computersystemen möglich gemacht werden, natürliche Sprache zu verstehen und zu bearbeiten, um die dafür gewünschten Aufgaben zu erfüllen. [13]

Der Ansatz zur Verarbeitung natürlicher Sprache lässt sich in vier Kategorien einteilen:

- Symbolisch
- Statisch
- Konnektionistisch
- Hybrid

Konnektionistische Ansätze erschienen erstmals in den 1960er Jahren. Symbolische Ansätze dominierten eine lange Zeit im Bereich des Natural Language Processing. In den 1980er Jahren gewannen die statischen Ansätze wieder an Popularität, da die nötigen Rechnerressourcen zur Verfügung standen. [14] In Abbildung 6.1 ist die von uns verwendete NLP-Pipeline zu sehen.

6.1.1 *Symbolischer* Ansatz

Der erste aufgelistete Ansatz zur Verarbeitung der natürlichen Sprache ist der symbolische Ansatz. Die führen eine tiefgehende Analyse linguistischer Phänomene durch und beruhen auf der expliziten Darstellung von Fakten über die Sprache durch wohlverstandene Wissensrepräsentationsschemata und dazugehörige Algorithmen. Die primäre Quelle der Evidenz in symbolischen Systemen sind die von Menschen entwickelten Regeln und Lexika.

6.1.2 *Statistischer Ansatz*

Statistische Ansätze verwenden verschiedene mathematische Techniken und nutzen oft große Textkorpora, um ungefähre verallgemeinerte Modelle linguistischer Phänomene zu entwickeln, die auf tatsächlichen Beispielen dieser Phänomene basieren, die von den Textkorpora geliefert werden, ohne signifikantes Linguistiken oder Weltwissen hinzuzufügen. Im Gegensatz zu symbolischen Ansätzen werden bei den statistischen Ansätzen beobachtbare Daten als primäre Beweisquelle genutzt.

6.1.3 *Konnektionistischer Ansatz*

Ähnlich wie bei den statistischen Ansätzen werden auch bei den konnektionistischen Ansätzen verallgemeinerte Modelle aus Beispielen sprachlicher Phänomene entwickelt. Was den Konnektionismus von anderen statistischen Methoden unterscheidet, ist die Tatsache, dass konnektionistische Modelle statistisches Lernen mit verschiedenen Repräsentationstheorien kombinieren - folglich erlauben die konnektionistischen Repräsentationen Transformation, Inferenz und Manipulation von logischen Formeln. Darüber hinaus sind linguistische Modelle in konnektionistischen Systemen schwieriger zu beobachten, da konnektionistische Architekturen weniger eingeschränkt sind als die statistischen.

6.1.4 *Hybrider Ansatz*

Hybride Ansatz des Natural Language Processings wurden dafür entwickelt, um die Stärken jedes Ansatzes zu nutzen, um NLP-Probleme effektiver und flexibler zu lösen.

6.2 Hauptaufgaben in Natural Language Processings

NLP kann für die automatisierte Zusammenfassung angewendet werden. Dabei wird die Methode dafür verwendet, um Zusammenfassungen oder detailliert Informationen aus dem Text zu liefern. Des weiteren wird NLP für die Auflösung von Koreferenzen, Analyse von Diskussionen und die automatische Übersetzung verwendet. [16]

6.3 Analyse des Sentiments

Für die Analyse der Daten werden Werkzeuge benötigt, um die Tweets zu bewerten. Um uns für eine Methode zu entscheiden haben wir beide Methoden miteinander verglichen, indem wir Tweets analysiert haben und den Wert der Polarity beurteilt haben. Nach einigen Tests ist uns aufgefallen, dass die Methode Polarity das Sentiment besser bestimmt als die Methodik der N-Grams. Die durchgeführten Ergebnisse wurden mit der Polarity Methode berechnet.




Abbildung 6.1: NLP-Pipeline

6.3.1 Polarity

Textblob ist eine Python Bibliothek, die für Aufgaben des Natural Language Processings verwendet wird. Nehmen wir an, dass wir der Methode den Satz “this is an awesome work“ so erreicht die Polarity Methode einen Wert von 1.0. Aus dem Wert ist zu entnehmen, dass der positiv ist. Das Intervall der Polarity ist zwischen -1.0 und 1.0. Erzielt ein Text eine Polarity kleiner 0, so ist dieser Text negativ. Ist der Wert größer 0, dann ist der übergebene Text positiv und erzielt der dieser den Wert 0, dann ist der Text somit neutral gehalten und es ist kein Sentiment in dem Text vorhanden.

6.3.2 Subjectivity

Unter der Subjectivity versteht man die Bewertung der Tweets nach persönlichen Gefühlen, Interessen oder der Voreingenommenheit der User. Diese Funktion wurde von der Bibliothek *preprocessor* zur Verfügung gestellt, unter den Namen *subjectivity*. Die Werte variieren zwischen null und eins, wobei null keine Subjektivität bedeutet und eins den Text als sehr subjektiv bewertet.

6.3.3 AFINN

AFINN ist eine weitere Python Bibliothek, die für die Analyse des Sentimentes verwendet werden kann. Die Methode unterstützt lediglich vier Sprachen. Diese sind Englisch, Spanisch, Französisch und Italienisch. Da es nur vier Sprachen sind, die unterstützt werden, ist die Analyse des Sentiments etwas schwierig, da wir 98 Sprachen aufgenommen haben in unserer Analyse. Das heißt, dass wir die restlichen 94 sprachen als neutral auswerten würden. Jedoch ist in der *Abbildung 8.16* zu erkennen, dass die Mehrheit (39.802.334 von 47.400.000 wären analysierbar, was einem prozentualen Anteil von 83,97 % entspricht) der Sprachen englisch, spanisch, französisch und italienisch ist.

6.3.4 N-Grams

N-Grams ist die Aufteilen eines Textes oder Satzes in Segmente. Bei der Zerlegung wird der Text in N aufeinanderfolgende Teile zerlegt und als N-Gram zusammengefasst. N-Grams ($N > 1$) sind im Allgemeinen informativer als einzelne Wörter und können als Feature für die Sprachmodellierung verwendet werden. N-Grams können in TextBlob einfach mit der Funktion `ngrams` berechnet werden. Dieser gibt ein Tupel aus n aufeinanderfolgenden Wörtern zurück.

6.3.4.1 Polarity vs. 2-Gram

Wie schaut die Auswertung aus, wenn wir für $N = 2$ wählen? Es werden also nur jeweils zwei Wörter auf einmal pro Tweet analysiert. Wenn man zum Beispiel den Satz "Weltmeisterschaft ist spannend" hat, dann wird die Polarity Berechnung auf die folgenden Wörter angewandt: 1. Weltmeisterschaft ist, 2. ist spannend. In diesem Beispiel werden beide Ergebnisse addiert und durch zwei geteilt, da man in diesem Fall 2 Ergebnisse hat und man sonst über den Wert 1 bzw. -1 kommen kann. Wir möchten den Wertebereich von -1 bis 1 nicht überschreiten, da die Polarity Berechnung, die wir verwendet haben auch nur einen Wertebereich von -1 bis 1 hat. Die Abbildung 6.2 zeigt blaue Säulen, die jeweils die Polarity eines Tweets darstellen, ohne die Nutzung von N-Grams. Sprich, die der gesamte Text wird als Input für die Polarity Berechnung verwendet. Die orangenen Säulen stellen die resultierende Polarity der jeweiligen Tweets dar, mit dem Unterschied, dass für die Polarity Berechnung 2-Gram verwendet wurde. Es ist deutlich zu erkennen, dass 2-Gram in allen Tweets schlechter abschneidet als die Polarity Berechnung ohne N-Grams, da die blauen Säulen einen höheren Ausschlag aufweisen. Mit anderen Worten, die blauen Säulen sind aussagekräftiger als die orangenen Säulen, da die blauen Säulen einen positiveren bzw. negativeren Wert aufweisen als die orangenen Säulen. Die einzige Gemeinsamkeit der beiden Ergebnisse sind die Polarity Werte bei null. Die Frage, die sich jetzt stellt, ist, warum die Ergebnisse von 2-Gram sich so stark von der Berechnung ohne N-Grams unterscheiden. Die Antwort ist simpel. Aufgrund der Division der Anzahl der entstandenen Grams werden die Werte dementsprechend gering. Um beispielsweise einen Wert von 1 zu erhalten, müsste jeder entstandende Gram einen Wert von 1 aufweisen. Das Gleiche gilt für den Wert -1. Es ist also nicht verwunderlich, warum 2-Gram eine Generalisierung darstellt bezüglich der berechneten Polarity in der Abbildung. Falls man die Ergebnisse nicht dividieren würde, dann wären zwar die 2-Gram Werte höher, aber man könnte keine Aussage mehr über die Polarity treffen, da die Polarity dann von der Länge des Tweets abhängig sein würde.

6.3.4.2 Polarity vs. 3-Gram

Wie schaut die Auswertung aus, wenn wir für $N = 3$ wählen? Was in Abbildung 6.3 sofort auffällt ist, dass 3-Gram wesentlich höhere Werte aufweist als 2-Gram. 3-Gram ist aber trotzdem nicht fähig, präzisere Werte als die normale Polarity Berechnung ohne N-Grams aufzuweisen. Außerdem kann man erkennen, dass die blauen Säulen die gleichen Werte aufweisen, wie in der vorherigen Abbildung. Dies ist nicht weiter verwunderlich, da der gleiche Datensatz von circa 200 Tweets verwendet wurde. Wir haben für die N-Gram Analyse den




Abbildung 6.2: Vergleich zwischen der Polarity und 2-Gram

gleichen Datensatz genommen, um die Ergebnisse besser miteinander vergleichen zu können. Außerdem ist auffällig, dass 3-Gram die gleiche Polarity hat wenn die Polarity ohne N-Gram null ist. Das bedeutet, dass beide Strategien neutrale Tweets gleich gut erkennen können.

6.3.4.3 Polarity vs. 4-Gram

Wie schaut die Auswertung aus, wenn wir für $N = 4$ wählen? Aus Abbildung 6.4 kann man schließen, dass 4-Gram zwar schon bessere Werte als 2-Gram und 3-Gram aufweist, aber trotzdem noch schlechter als ohne N-Gram ist. Bei Tweet Nummer 51 schafft es 4-Gram sogar einen gleichen Polarity Wert größer null aufzuweisen wie ohne N-Gram. Es sieht so aus, dass ein höher gewähltes N bei N-Grams, höhere Polarity Werte aufweist. Im folgenden Vergleichen wir die Ergebnisse von 5-Gram mit der Polarity ohne N-Gram, um zu untersuchen, ob die Annahme korrekt ist oder nicht.

6.3.4.4 Polarity vs. 5-Gram

Wie schaut die Auswertung aus, wenn wir für $N = 5$ wählen? Der Verdacht hat sich bestätigt. Die Polarity von 5-Gram ist tatsächlich angestiegen, erreicht aber noch nicht die Polarity Werte ohne N-Gram (Abbildung 6.5). Daraus kann man schließen, dass die N-Gram Methodik unzureichend ist im Vergleich zu der Polarity Berechnung ohne N-Gram. Aufgrund dieses Ergebnisses haben wir sämtliche Polarity Berechnungen ohne N-Grams ausgeführt, da dies eine Methodik ist, die sich am besten bewährt hat.




Abbildung 6.3: Vergleich zwischen der Polarity und 3-Gram




Abbildung 6.4: Vergleich zwischen der Polarity und 4-Gram




Abbildung 6.5: Vergleich zwischen der Polarity und 5-Gram

6.4 Grund für die Nicht-Verwendung der Analyse von Emojis

Die Verwendung von Emojis spielt in der Analyse des Sentiments eine wichtige Rolle. Denn anhand dieser wäre es möglich entweder Ironie oder Sarkasmus zu erkennen. Emojis sagen viel über das Sentiment der jeweiligen Person aus im Zusammenhang mit dem verfassten Text. So wäre es leichter möglich diese zu analysieren und Doppeldeutigkeiten besser zu erkennen. Jedoch ist das Problem dieser Bibliothek, dass die Anzahl der Datensätze, mit der diese Bibliothek trainiert wurde, zu klein ist. Das Problem ist, dass aufgrund von zu geringen Trainingsdaten die Werte der Methode die Sentimentanalyse verfälschen könnten. Die Bibliothek hat ungefähr 100.000 Emojis analysiert. Das klingt zwar nach einer hohen Anzahl, jedoch wurden für diese Analyse über 700 Emojis verwendet. Das am meisten untersuchte Emoji hat über 10.000 Samples was ausreichend gewesen wäre, aber es gibt auch Emojis in dieser Untersuchung, die weniger als 100 Samples hatte, was wiederum zu wenige Samples sind, um eine korrekte Analyse der Emojis zu garantieren. Außerdem ist auch bei einer hohen Anzahl an Testdaten keine Korrektheit des Sentiments eines Emojis garantiert. Das am meisten analysierte Emoji ist der Tränen lachende Smiley. Wie der Tabelle zu entnehmen ist, ist es trotz der vielen Erscheinungen schwer zu sagen, was das Emoji aussagt, da dieser Smiley mehrere Bedeutungen haben kann. Manchmal fällt es sogar dem Menschen selbst schwer, die Bedeutung eines Emojis zu deuten. Wenn es für den Menschen schon schwierig ist, wie soll dann eine Maschine die Erscheinung von Emojis bewerten? Natürlich gibt es auch Emojis, die meist nur einen Zweck haben, wie beispielsweise das Herz Emoji auf Platz zwei und Platz drei in der Tabelle. Wie aber auch der Tabelle zu entnehmen ist, wird auch das Herz Emoji manchmal für negative Tweets benutzt. Deshalb befindet sich der Sentiment Score auch nicht auf eins, sondern liegt bei circa 0,7. Auf Platz fünf befindet sich auch ein schwer zu deutendes Emoji. Es ist ein weinender Smiley. Die Bezeichnung des Smileys deutet zwar auf ein negati-

Char	Image [twemoji]	Unicode codepoint	Occurrences [5...max]	Position [0...1]	Neg [0...1]	Neut [0...1]	Pos [0...1]	Sentiment score [-1...+1]	Sentiment bar (c.i. 95%)	Unicode name	Unicode block
😭		0x1f602	14622	0.805	0.247	0.285	0.468	0.221		FACE WITH TEARS OF JOY	Emoticons
♥		0x2764	8050	0.747	0.044	0.166	0.790	0.746		HEAVY BLACK HEART	Dingbats
♥		0x2665	7144	0.754	0.035	0.272	0.693	0.657		BLACK HEART SUIT	Miscellaneous Symbols
😊		0x1f60d	6359	0.765	0.052	0.219	0.729	0.678		SMILING FACE WITH HEART-SHAPED EYES	Emoticons
😭		0x1f62d	5526	0.803	0.436	0.220	0.343	-0.093		LOUDLY CRYING FACE	Emoticons
😘		0x1f618	3648	0.854	0.053	0.193	0.754	0.701		FACE THROWING A KISS	Emoticons
😊		0x1f60a	3186	0.813	0.060	0.237	0.704	0.644		SMILING FACE WITH SMILING EYES	Emoticons
👌		0x1f44c	2925	0.805	0.094	0.249	0.657	0.563		OK HAND SIGN	Miscellaneous Symbols and Pictographs
💕		0x1f495	2400	0.766	0.042	0.285	0.674	0.632		TWO HEARTS	Miscellaneous Symbols and Pictographs
👏		0x1f44f	2336	0.787	0.104	0.271	0.624	0.520		CLAPPING HANDS SIGN	Miscellaneous Symbols and Pictographs
😄		0x1f601	2189	0.796	0.127	0.296	0.577	0.449		GRINNING FACE WITH SMILING EYES	Emoticons
😊		0x263a	2062	0.799	0.062	0.218	0.720	0.657		WHITE SMILING FACE	Miscellaneous Symbols

Abbildung 6.6: Die am meisten analysierten Emojis

ves Sentiment, aber es kann durchaus für positive Tweets verwendet werden. Diese Beispiele führen zu dem Resultat, weshalb wir diese Bibliothek nicht verwendet haben. Und zwar wird den Emojis ein fester Sentiment Wert gegeben, was die Analyse unbrauchbar macht, da wir bereits festgestellt haben, dass Emojis zu verschiedenen Zwecken eingesetzt werden können. Man kann also den Sentiment Score nicht pauschalisieren! Aufgrund dessen haben wir uns dafür entschieden, bei der Berechnung der Polarity, die Emojis vorher zu entfernen.

7 Erwartungen

7.1 Hypothesen

Für die Auswertung unserer Daten hatten wir im vornhinein Hypothesen. Die Weltmeisterschaft ist eine Veranstaltung von Nationalitäten. Das führt oft dazu, dass Menschen emotionaler sind, da der Nationalstolz mitwirkt. Hinzu kommt die Begeisterung vieler Menschen weltweit zum Fussball. Die oben genannten Gründe bieten ein hohes Potential für die Sentimentanalyse. In den folgenden Auswertungen wird überprüft, ob unsere Hypothesen der Realität entsprechen. Natürlich können diese Hypothesen nicht wissenschaftlich belegt werden, da es sonst keine Hypothese mehr wären. Deswegen beruhen unsere Gründe für die Hypothesen auf Vorurteilen und Erwartungen.

Unsere erste Hypothese ist, dass die publizierten Tweets über Schiedsrichter hauptsächlich negativ sind. Wir kommen zu dieser Hypothese, da sowohl im Stadion, als auch in öffentlichen Lokalen der Schiedsrichter größtenteils als Sündenbock dargestellt wird. Außerdem sind wir der Meinung, dass die meisten Kommentare auf einer hohen emotionalen Ebene heraus entstehen und deshalb nur wenige Kommentare einen hohen qualitativen Wert haben. Dies führt zur nächsten Hypothese, dass ein retweet auf Basis eines hohen Sentiments beruhen. Mit anderen Worten, es werden die Tweets nochmals getweetet, die sehr Emotional sind, da meist emotionale Tweets in Einklang des emotionalen Befindens anderer User übereinstimmen. Durch diese Erwartung haben wir auch die Hypothese, dass es sich bei den am meisten geposteten Tweets um Tweets handelt, die entweder sehr positiv oder sehr negativ sind. Zudem haben wir die Hypothese, dass die meisten Tweets aus Südamerika und Europa kommen, da in Südamerika die WM 2014 in Brasilien stattgefunden hat. Europa ist zwar vergleichsweise zu anderen Kontinenten klein, aber hat dennoch das Potential für viele Tweets, da die besten Fußballspieler aus Europa kommen und zudem Fußball besonders in Europa ein hohes Ansehen hat im Gegensatz zu anderen Kontinenten wie Australien oder Nordamerika. Des Weiteren haben wir die Hypothese, dass es sich bei den am meisten geposteten Hashtags um Hashtags handelt, die generell etwas über die WM aussagen und deswegen als "Weltmeisterschaftstituliert sind. Außerdem gehen wir davon aus, dass auch Hashtags über Fußballspieler und Schiedsrichter häufig in Erscheinung treten, da man viel über diese Themen kommentieren kann und sowohl Fußballspieler, als auch Schiedsrichter gute Themen sind, um seine subjektive Meinung zu äußern (sowohl negative, als auch positive). Des Weiteren haben wir die Hypothese, dass die meisten Tweets auf Englisch sind. Englisch ist bekannt für den Status als Weltsprache. Dies hat sich im Laufe der Jahre in jedem Land etabliert und ist deswegen auch die am meisten gesprochene Sprache. Außerdem ist Englisch eine leicht zu erlernende Sprache im Vergleich zu anderen Sprachen wie Deutsch, Polnisch oder Japanisch.

8 Auswertung

Im Folgenden haben wir unsere Datensätze ausgewertet und analysiert. Zu Beginn haben wir mit Zählabfragen gestartet. Dabei haben wir analysiert, welche Städte und Länder am dominantesten waren und welche Sprache am meisten verwendet wurde. Die Gruppierung nach der Sprache haben wir vollzogen, da wir das Problem hatten, dass viele Attribute für die Stadt oder das Land den Wert *null* hatten. Die Anzahl der Tweets, die Informationen über die Stadt oder das Land enthielten waren lediglich 1.192.397 Tweets von gesamt 47,4 Millionen. Das ist ein Anteil von 2,5 Prozent. Die Anzahl der Tweets, die Informationen über die Sprache und somit auch über die Herkunft hatten, waren deutlich über der Gesamtzahl der Tweets, die Länder und Städte enthielten. Dies ist aus der *Abbildung 8.3* zu entnehmen. Anhand der hohen Anzahl an Daten war es möglich deutlich bessere Analysen zu generieren. Um aussagekräftige Werte zu generieren haben wir zudem die Auswertung nach der Zeitzone vollzogen. Anhand dieser war es möglich, über 30 Millionen Tweets zu behandeln. Danach haben wir die Hashtags analysiert, die während der Weltmeisterschaft am meisten verwendet worden sind. Diese Schritte haben wir vollzogen, um zu sehen, ob Auffälligkeiten zu erkennen sind. Anhand des Zählens der Daten vor der Sentimentanalyse, war es uns möglich, Auffälligkeiten zu analysieren und Untergruppen zu finden. Im nächsten Schritt haben wir mit der Analyse der Tweets begonnen und haben zu Beginn die am meisten retweeteten Tweets der Weltmeisterschaft 2014 analysiert. In diesem Abschnitt haben wir zudem angefangen, die Polarity der Tweets zu bestimmen und zu testen, ob die Werte der Polarity passend sind. Danach haben wir die Verteilung der Polarity bestimmt, wie diese während der Weltmeisterschaft 2014 ausgefallen sind. In *Abschnitt 8.7* haben wir die Tweets analysiert, die Schiedsrichtererwähnungen beinhalten. Danach haben wir uns die Frage gestellt, ob ein Zusammenhang zwischen dem Sentiment und der Anzahl der Retweets besteht. Anschließend haben wir die Verteilung der Polarity der Tweets analysiert, die Schiedsrichtererwähnungen enthalten und haben diese graphisch ausgewertet.

8.1 Städte, die am meisten getweetet haben

Als Ansatz, um zu analysieren, welche Städte während der Weltmeisterschaft am aktivsten waren, haben wir die Tweets in Städte gruppiert und die Anzahl der jeweiligen Städte ausgegeben. Jedoch hatten wir das große Problem, dass viele Tweets keine Angaben zu den Koordinaten und Städten haben, weshalb wir im späteren Verlauf die Analyse anhand der Zeitzone und der Sprache vollzogen haben. Insgesamt haben wir 1.192.397 Tweets von 47.4 Millionen, die Städten zugeordnet worden sind. Das macht einen prozentualen Anteil von circa 2,5 aus. Es ist also nur ein verschwindet kleiner Anteil, der untersucht werden kann. Der Grund ist, dass es keine Angabepflicht ist, die Stadt bei den Twitter Accounts anzugeben. Obwohl der Anteil so gering ist, interessiert es uns trotzdem, welche angegebenen Städte die größte Beteiligung an Tweets haben während der Fußballweltmeisterschaft 2014. Rio de

Städte, die am meisten getweetet haben

von insgesamt 1.192.397




Abbildung 8.1: Verteilung der Tweets in Bezug auf die Städte
Abbildungcities

Janeiro, Porto Alegre und Sao Paulo zählen zu den Städten, die angegeben waren, die am meisten getweetet haben. Der Grund für die hohe Anzahl ist, dass der Austragungsort in Brasilien war und zudem das brasilianische Volk zu denen gehört, die die Sportart Fussball am meisten zelebrieren. Einen großen Anteil in den Top 10 Städten übernehmen amerikanische Städte wie New York, Los Angeles, Texas und Florida. Das zeigt die Begeisterung der amerikanischen Bevölkerung gegenüber der Ballsportart. Was am Anfang verwirrend aussieht, ist der geringe Anteil der Städte, die am meisten getweetet haben. Die am meisten getweeteten Städte machen nicht einmal einen Anteil von ein Achtel aus. Das liegt daran, dass es sehr viele Städte auf der Welt gibt. Wenn man jede in Twitter registrierte Stadt in Betracht zieht, dann wirkt das Ergebnis dieses Kuchendiagramms nicht mehr unrealistisch, sondern durchaus plausibel.

8.2 Länder, die am meisten getweetet haben

Für die nächste Untersuchung haben wir fast 1,2 Millionen Tweets in Länder gegliedert, um zu sehen, welche Nation während der Weltmeisterschaft am meisten getweetet hat. Hier haben wir wiederum das selbe Problem, wie bei der Gruppierung in Städte, da viele Tweets keine Angaben zu den Koordinaten haben. Wie in *Abbildung 8.12* zu sehen ist, haben wir die Länder in 11 Gruppen geteilt. Diese sind die Top 10 und die restlichen Länder wurden aufgrund des geringen Anteils zusammengefasst.

Länder, die am meisten getweetet haben

von insgesamt 1.192.397




Abbildung 8.2: Verteilung der Tweets in Bezug auf die Länder
Abbildungcountries

8.3 Sprachen, die am meisten getweetet haben

Im folgenden Absatz haben wir die Analyse der Sprachen fortgeführt, die während der Weltmeisterschaft 2014 am meisten am aktivsten waren. Englisch ist mit über 31.060.489 Tweets die am meisten verwendete Sprache. Der Grund dafür ist, dass England eine der am meisten gesprochenen Sprachen ist. Die am zweitmeisten verwendete Sprache ist Spanisch. Mit 6.472.621 Tweets liegt diese deutlich vor der portugiesischen Sprache. Das liegt daran, dass in Mexiko, Kolumbien und vor allem Spanien und Argentinien die Sprache Spanisch verwendet wird. Spanien und Argentinien sind sehr fussballbegeisterte Nationen und aufgrund dessen ist die Anzahl der Tweets so hoch. Ein Grund weshalb Kolumbien auch ausschlaggebend für die hohe Anzahl ist, ist dass die Weltmeisterschaft 2014 eine Ausnahme für die Kolumbianer war. Kolumbien erreichte in der Weltmeisterschaft das Viertelfinale und scheiterte gegen Brasilien aus. Hinzu kommt, dass der kolumbianische Nationalspieler James Rodriquez zum Torschützenkönig der Weltmeisterschaft 2014 gekürt wurde und somit alle namenhaften Spieler in den Schatten stellte. Portugiesisch ist mit 2.545.399 Tweets auf dem dritten Platz. Das liegt vor allem daran, dass dies die offizielle Landessprache in Portugal und Brasilien ist und Brasilien in der Weltmeisterschaft den dritten Platz erreicht hat.

8.4 Meisten Tweets in Abhängigkeit der Zeitzone

Aufgrund des Problems, dass 46.207.603 Tweets keiner Stadt oder keinem Land zugeordnet waren, haben wir die Tweets nach der Zeitzone gruppiert, um zu sehen welcher Bereich der Welt am meisten mitgefebert hat. Nach der Analyse von 30.265.688 Tweets haben wir

Anzahl der Tweets in der jeweiligen Sprache




Abbildung 8.3: Verteilung der Tweets in Bezug auf die Sprache
Abbildungslanguages

festgestellt, dass Nutzer, die aus der Zeitzone der Eastern Time (USA Kanada) kommen, am meisten getweet haben. Ein Grund dafür ist, dass diese Zeitzone eine hohe Populationsdichte hat. Außerdem befindet sich New York auch in dieser Zeitzone, bei der wir bereits festgestellt haben, dass viele Tweets von New York kommen. Die darauf folgende Zeitzone ist die brasilianische Zeitzone, diese haben während der Weltmeisterschaft ungefähr drei Millionen Tweets gepostet. Daraus ist deutlich zu erkennen, dass die Länder der brasilianischen Zeitzone einer der begeistertsten Nationen auf der Welt sind. Die nächsten beiden Zeitzonen mit 9,6 % und 9,7 % der gesamten Tweets sind europäische Zeitzonen.

8.5 Am meisten verwendeten Hashtags in/während der Weltmeisterschaft

- 1. worldcup (12.874.579)
- 2. worldcup2014 (7.132.034)
- 3. brasil2014 (3.516.070)
- 4. brazil (1.190.763)
- 5. usa (1.055.780)

Anzahl der Tweets (Zeitzone)




Abbildung 8.4: Verteilung der Tweets in Bezug auf die Zeitzone
AbbildungtimeZone

Anzahl der Tweets, in den Zeitzonen

von insgesamt 30.265.688




Abbildung 8.5: Anzahl der Tweets, gruppiert nach den Zeitzonen
AbbildungTweetsTimezone




Abbildung 8.6: Die am häufigsten verwendeten Hashtags

- 6. fifa (933.043)
- 7. bra (893.871)
- 8. mundial2014 (804.861)
- 9. cm2014 (753.832)
- 10. brasil2014 (732.977)

Es wurden insgesamt 73.419.523 Hashtags gepostet. Das heißt, dass der am häufigste gepostete Tweet, mit einer Anzahl von 12.874.579 Vorkommen, 17,5 Prozent aller Hashtags ausmacht. Auf dem zweiten Platz ist auch worldcup mit den Zahlen 2014 als suffix, was im Grunde genommen die gleiche Bedeutung des Tweets kundgibt. Was aber bemerkenswert ist, ist Platz drei und Platz vier. Der Hashtag auf Platz 3 ist brasil2014 und nicht brazil2014, was die englische Schreibweise für Brasilien gewesen wäre. Das heißt, dass die meisten Hashtag Nutzer die portugiesische Schreibweise bevorzugt haben, anstatt der englischen Schreibweise. Erstaunlich ist der fünfte Platz, da unsere Hypothese die USA (Nordamerika) als eher unwichteres Land im Sinne der Fußball Weltmeisterschaft eingestuft hat. Der sechste Platz ist der Hashtag fifa. FIFA ist der Veranstalter der Fußball Weltmeisterschaft und kann in Verbindung mit dem Schiedsrichter gesetzt werden. Somit bestätigt sich unsere Hypothese teilweise, dass Schiedsrichter einer der häufigsten Themen in den Tweets sind. Auf Platz sieben ist "bra", was die Abkürzung von brasil bzw. brazil ist. Wie man in der Liste sehen kann, kommt der Hashtag Brasilien insgesamt vier mal vor (Platz 3, 4, 7, 10). Rechnet man alle zusammen ergibt sich ein Prozentanteil von 8,6 zu allen Hashtags. Auf Platz acht ist mundial2014. mundial ist portugiesisch und heißt übersetzt Weltmeisterschaft. Wenn man alle Hashtags mit dem Titel Weltmeisterschaft (worldcup, worldcup2014, mundial2014) zusammenzählt, dann kommt man auf einen Anteil von 28,3 Prozent aller Hashtags. Das heißt, dass über ein Viertel




Abbildung 8.7: Die Anzahl der Top 10 Tweets

aller Hashtags das Thema Weltmeisterschaft hatten, was nicht verwunderlich ist, da die zu untersuchenden Tweets über das Thema der Weltmeisterschaft 2014 handelten. Auf Platz 9 ist der Hashtag cm2014 zu sehen. Jedoch konnten wir keine Rückschlüsse über dessen Bedeutung machen. Zusammenfassend haben sich unsere Hypothesen nur teilweise bestätigt. Zum einen sind die häufigsten Hashtags über die Fußballweltmeisterschaft. Zum anderen sind nur indirekt Schiedsrichter und keine Fußballspieler in den Top 10.

Der siebte Tweets erhält aufgrund der Intention des Users eine hohe Anzahl an Retweets. Dieser tweetet, dass Messi Argentinien, Neymar Brasilien und British Airway das Vereinigte Königreich durch die Weltmeisterschaft bringt. Das liegt meist an der Konstellation der Nationalmannschaft, da diese meist aus einem Schlüsselspieler bestehen, welcher das Spiel meist entscheidet. Diese Thematik wird im Fussball sehr oft diskutiert.

8.6 Am meisten getweeteten Tweets während der Weltmeisterschaft 2014

Im Folgenden haben wir die Tweets analysiert, die während der Weltmeisterschaft die meisten Retweets hatten. Anhand dieser konnten wir erkennen, welche Themen in den sozialen Medien am meisten besprochen wurden.

Top 10 Tweets, die während der Weltmeisterschaft 2014 aufgefasst wurden mit der Anzahl der Retweets

- 1. Anzahl: 66362, great football on today ! can't wait !




Abbildung 8.8: Die Polarity der Top 10 Tweets

- 2. Anzahl: 44308, hey @luis16suarez. next time you're hungry just grab a snickers. worldcup luissuarez eatasnickers <http://t.co/3rao537hgw>
- 3. Anzahl: 33612, it's a monster of a day! we are playing in the heart of italian football, the home of ac and inter milan , san siro! excited=understatement
- 4. Anzahl: 28020, ochoa!! incredible mexico worldcup
- 5. Anzahl: 19589, congrats brazil!!!
- 6. Anzahl: 19577, been getting so many tweets from brazil! shout out to brazil!!! <http://t.co/dosozlk7n>
- 7. Anzahl: 18543, messi carrying argentina. neymar carrying brazil.....british airways carrying england.
- 8. Anzahl: 17964, fifa <http://t.co/jv9a7st9fr>
- 9. Anzahl: 17519, rt if your country is in the second round worldcup ned arg crc col chi bra mex bel crc uru nga fra sui usa ger
- 10. Anzahl: 16072, brazil!!!! worldcup2014 tamos juntos! <http://t.co/iik8udilee>

Der am meisten retweetete Text weist deutlich auf die Zuneigung der Menschen gegenüber der Ballsportart hin. In dem nächsten Tweet, der 44.308 mal retweeted wurde, geht es um eines der bekanntesten Ereignisse während der Weltmeisterschaft 2014. Daran ist deutlich zu sehen, dass das Geschehen auf dem Feld auf sozialen Netzwerken diskutiert wird.

Während des Spiel der Uruguay gegen Italien bis der Profifußballer Luis Suarez den italienischen Spieler Giorgio Chiellini. In Abbildung 7.1 ist dies deutlichst zu sehen.

Nach dieser Bissattacke erhielt Suarez eine Sperre von 9 Spielen für Pflichtspieler seiner Nationalmannschaft. Zudem musste dieser eine Strafe von 100.000 Schweizer Franken begleichen.



Abbildung 8.9: Der Augenblick an dem Luis Suarez den italienischen Spieler Chellini biss [9]

[10] Wenige Minuten nach der Attacke Suarez wurde dieser in den oben genannten Tweet markiert und wurde auf einer sarkastischen Art verhöhnt. Dies geschieht anhand dessen, dass dieser ein Snickers essen soll, da er aufgrund seiner Hungers nicht er selber sei. Dies ist ein Verweis auf die Werbung der Marke Snickers. Diese haben immer wieder den gleichen Ablauf und können in der Quelle [11] nachgesehen werden. Jedoch ist daraus zu schließen, dass die Polarity keinen Sarkasmus erkennt, dass dieser Tweet eine Polarity von 0.0 hat.

Der nächste Tweet wurde am 28.06.2014 getweetet. An diesem Tag begann das Achtelfinale nach der Gruppenphase. Jedoch ist dies verglichen mit den anderen Tweets kein besonderes Ereignis. Der eigentliche Grund für die Anzahl der Tweets könnte daran liegen, dass der Nutzer eine Person des öffentlichen Lebens ist. Dieser heißt Niall Horan und hat aktuell 41.3 Millionen Follower. Tweets, die von bekannten Personen verfasst werden erhalten im Gegensatz zu normalen Nutzern deutlich mehr Resonanz. Ein weiterer Tweet, der eine geringfügiges Sentiment hat ist der 5 Tweet, welcher fast 20.000 mal retweetet wurde. Dieser Tweet wurde von dem US-Amerikanischen Popsänger Austin Mahone getweetet. Aufgrund der hohen Anzahl an Followern erhielt der Tweet eine große Anzahl an Retweets.

8.7 Verteilung der Polarity aller Tweets der Weltmeisterschaft 2014

Im vorliegenden Abschnitt haben wir das Sentiment aller Tweets analysiert, die während der Weltmeisterschaft 2014 getweetet wurden. Wichtig hinzuzufügen ist, dass es bei dieser Auswertung keine Duplikate gibt. In *Abbildung 8.10* ist deutlich zu erkennen, dass die Mehrzahl der Tweets neutral sind. Damit wurde unsere erste Hypothese widerlegt, dass die Tweets der Nutzer, aufgrund des Nationalstolzes und der Liebe zum Fußball, sentimental sein würden. Jedoch ist in der *Abbildung 8.10* und *8.11* zusätzlich zu sehen, dass wir deutlich mehr positive Tweets haben als negative. Zudem ist die Anzahl der subjektiven Tweets wesentlich




Abbildung 8.10: Verteilung der Polarity aller Tweets während aller Tweets

höher als die Anzahl der Tweets, die objektiv formuliert sind.

8.8 Alle Tweets mit Erwähnungen des Schiedsrichters

Zu Beginn der Analyse haben wir uns damit beschäftigt, welche Person während der WM am meisten kommentiert wird. Der Schiedsrichter ist in jedem Spiel der Mittelpunkt, da dieser Entscheidungen trifft, die das Spielgeschehen verändern können. Hinzu kommt, dass es in der Weltmeisterschaft 2014 keine Videoassistenten gibt. Dies führt dazu, dass Fehlentscheidungen des Schiedsrichters nicht kontrolliert werden können und die Zuschauer, die die Veranstaltung zuhause verfolgen, können ihre Meinung anhand von sozialen Netzwerken - hier: Twitter - teilen. Ohne den Videoassistenten kann nicht festgestellt werden, ob es sich tatsächlich um eine Fehlentscheidung handelt oder nicht. Deshalb gehen wir davon aus, dass viele Tweets als Thematik den Schiedsrichter und dessen Entscheidungen haben.

Top 5 Tweets, die den Schiedsrichter erwähnen mit der Anzahl der Retweets

- 1. respect big man !!!! football is not everything, 4323 Duplikate
- 2. fifa must have pulled some random people off the streets and made them referees, 3323 Duplikate
- 3. top talking point from last nights worldcup: referees beeing able to draw lines on the gras at freekicks, 2917 Duplikate
- 4. how fifa picks their refs, 2441 Duplikate
- 5. fifa referees, 2385 Duplikate




Abbildung 8.11: Verteilung der Polarity und Subjectivity von allen Tweets

8.8.1 Je mehr Duplikate, desto mehr Sentiment?

Die Tweets, die Schiedsrichtererwähnungen enthalten haben wir dadurch bekommen, indem wir alle Tweets ausgegeben haben, die das Wort *referee*, *ref*, *umpire*, *arbitrator*, *arbitrator*, *arbitro* oder *adjudicator* enthalten. Nun haben wir uns die Frage gestellt, ob die Anzahl der Duplikate Auswirkungen auf das Sentiment hat. Hat ein Tweet, welcher eine höhere Anzahl an Duplikaten besitzt, mehr Sentiment als ein Tweet mit geringerer Anzahl an Duplikaten. Nun werden die oben gegebenen Tweets betrachtet. Der erste bis zum vierten Tweet weisen einen hohen Sentiment auf. Der erste Tweet ist positiv gehalten und weist darauf hin, dass dieser Fussball nicht alles im Leben ist und diese die Person respektieren. Der Wortteil *ref* ist in den Hashtags enthalten. Die darauf folgenden drei Tweets sind negativ gegenüber des Schiedsrichters gehalten. Der zweite Stichpunkt stellt das Können des Schiedsrichters in Frage, da dieser sagt, dass die FIFA zufällige Leute von der Straße aufgreift und diese als Schiedsrichter einstellt. Dieser Tweet ist etwas schwieriger zu analysieren, da der erste Satz kaum Sentiment aufweist, jedoch kann der nächste Satz als negativ aufgenommen werden, da Schiedsrichter in der Lage seien Linien auf den Rasen zu zeichnen für Freistöße. Der Schiedsrichter wird dabei als unfähige Person dargestellt, die nur dazu fähig ist, die weißen Linien auf dem Fußballfeld zu zeichnen. Dies ist eine Satire, da die Fähigkeit des Schiedsrichters auf das Zeichnen der weißen Linien begrenzt wird und er für diese "leichte" Aufgabe nicht einmal verantwortlich ist. Der vierte Tweet ist wieder negativ, aufgrund des Satzes, welches den Aufbau einer rhetorischen Frage hat. Dieser entstand am 13.Juni.2014. An diesem Tag spielten Mexiko gegen Kamerun und Spanien gegen die Niederlande. Aufgrund der Unzufriedenheit der User mit dem Schiedsrichter, machten diese es auf dem sozialen Netzwerk bemerkbar.

8.9 Alle Tweets über den Schiedsrichter: Vergleich mit und ohne Duplikate

In der Abbildung mit der Überschrift “Alle Tweets über den Schiedsrichter: Vergleich mit und ohne Duplikate in Bezug auf die Polarity“ werden sowohl Tweets über den Schiedsrichter mit Duplikaten als auch ohne Duplikate betrachtet. Dabei steht die hellblaue Linie für die Anzahl der Tweets ohne Duplikate. Das bedeutet, dass jeder Tweet nur genau ein mal vorkommt. Mit anderen Worten werden Tweets, die den gleichen Inhalt haben, zusammengefasst als ein Tweet. Würde es zum Beispiel sechs Tweets geben, wovon aber drei den gleichen Text haben, dann würden nur vier in die Analyse mit einbezogen werden, da es in diesem Fall nur vier verschiedene Tweets geben würde. Die dunkelblaue Linie hingegen steht für die Anzahl der Tweets mit Duplikaten. Das heißt, dass alle Tweets in die Analyse einbezogen wurden. Dies gilt sowohl für Tweets, die keine mehrfach vorkommen haben, als auch für Tweets, die repostet wurden. Die x-Achse steht für die Polarity und ist untergliedert in drei Bereiche. Diese drei Bereiche sind Positiv, Neutral und Negativ. Unter der Kategorie Positiv fallen Tweets, deren Polarity bei der Analyse einen Wert von über 0.0 hatten. Das heißt, dass der Polarity Wert größer null ist und somit als positiver Tweet erkannt wurde. Unter den Bereich der neutralen Tweets fallen diejenigen, deren Polarity Wert genau 0.0 ist. Mit anderen Worten konnten keine konnotativen Ausschläge des Tweets festgestellt werden. Die letzte Kategorie ist als Negativ gekennzeichnet. In diese Kategorie können nur Tweets fallen, wenn diese einen Polarity Wert von kleiner 0.0 haben. Sprich, der Tweet wurde inhaltlich als negativ annotiert. Die hellblaue Linie stellt eine Anzahl von gesamt 28.573 Tweets dar, wenn man alle drei Bereiche zusammenzählt. Davon sind insgesamt 8988 positive Tweets. Das ist ein Prozentanteil von circa 31,5. Das bedeutet, dass jeder dritte Tweet über Schiedsrichter positiv war, sofern man die Duplikate nicht mitzählt. Unter der Kategorie der neutralen Tweets fallen 11972, also ein Prozentsatz von 41,9. Dieses Ergebnis resultiert daraus, dass die Polarity Analyse nur konnotativ die Sätze betrachtet. Es kann also beispielsweise keine Satire erkennen, sondern nur die Wörter in Bezug auf deren Bedeutung deuten. Die Anzahl der negativen Tweets liegt bei 7613. Das ist ein Wert von rund 26,7 Prozent. Dieses Resultat ist außergewöhnlich, da es nicht unserer Annahme entspricht. Unsere Hypothese war nämlich, dass es weitaus mehr positive und negative Tweets gibt, als neutrale Tweets. Es zeigt sich aber, dass rund 42 Prozent aller Tweets neutral sind. Hinzuzufügen ist außerdem, dass zwar nicht alle neutralen Tweets gedeutet werden konnten, es aber wahrscheinlich kein Großteil ausmacht. Die neutralen Tweets haben einen großen Abstand im Vergleich zu positiven oder negativen Tweets, was nicht unserer Hypothese entspricht. Auch bei Betracht der Tweets mit Einbeziehung von Duplikaten sieht es so aus, als würde unsere Hypothese nicht der Wahrheit entsprechen. Der Gesamtanteil der dunkelblauen Linie liegt bei 174.068. Davon sind 45.885 Tweets positiv, was einen Prozentanteil von 26,3 ist. Im Vergleich zu den Tweets ohne Einbezug von Duplikaten sind die Anzahl von positiven Tweets von 31,5 auf 26,3 Prozent gefallen. Das bedeutet, dass mehr neutrale oder/und negative Tweets retweetet werden als positive. Um zu untersuchen, welche Tweets häufiger retweetet wurden, analysieren wir nun die Anzahl der neutralen Tweets, die bei 92.160 liegt. Das ist ein Prozentsatz von circa 52,9. Das ist ein Anstieg von 11 Prozent, da die neutralen Tweets einen Prozentsatz von 41,9 haben und die neutralen Tweets mit Duplikaten einen Prozentsatz von 52,9 haben. Die negativen Tweets hingegen haben eine Gesamtanzahl von 36023, also 20,7 Prozent. Im Vergleich zu den negativen Tweets ohne Duplikate ist das ein Fall von 26,7 Prozent auf 20,7

Polarity der Tweets




Abbildung 8.12: Alle Tweets über den Schiedsrichter: Vergleich mit und ohne Duplikate in Bezug auf die Polarity

Prozent. Das bedeutet, dass mit Einbezug von Duplikaten sowohl die positiven, als auch die negativen Tweets prozentual von der Gesamtheit aller Tweets gefallen sind, während die neutralen Tweets angestiegen sind. Dieses Ergebnis entspricht nicht unserer Hypothese! Aus dem Graphen ist deutlich zu erkennen, dass besonders viele Tweets retweetet wurden. Sowohl positive, als auch negative Tweets und insbesondere neutrale Tweets. Ein Grund dafür sind prominente Personen, die etwas posten, da diese posts dann weitergeschickt werden und sich somit schneller verbreiten.

8.9.1 Verteilung der Polarity von Tweets mit Schiedsrichterwähnungen

In *Abbildung 8.14* haben wir die Subjectivity und Polarity mit der kMeans Methode geclustert. Das Clustering hat Vor- und Nachteile. Der Nachteil ist, dass keine Gruppierungen der jeweiligen Punkte zu erkennen ist. Jedoch konnten die Cluster nach der Polarity und Subjectivity gruppiert werden. Das blaue, rote und grüne Cluster stellt die jeweilige Gruppierung der Polarity Klassen dar mit hoher Subjectivity. Das blaue Cluster repräsentiert dabei eine negative Polarity. Im roten Cluster befinden sich Tweets, die einen relativen neutralen Polarity Score haben und das grüne Cluster zeigt Tweets, die eine hohe Polarity aufweisen. Das pinke Cluster stellt die Tweets dar, die zwar einen neutralen Polarity Wert haben, aber im Gegensatz zu den anderen Clustern sehr objektiv gehalten sind. Außerdem kann man aus der Grafik lesen, dass eine höhere Subjectivity zu einer Ausbreitung der Polarity führt. Mit




Abbildung 8.13: Verteilung der Polarity von Tweets, die Schiedsrichtererwähnungen enthalten




Abbildung 8.14: Clustering der Polarity und Subjectivity der Tweets des Schiedsrichters

anderen Worten führen die persönlichen Interessen beziehungsweise die Voreingenommenheit der User zu höheren Ausschlägen darüber, ob ein Tweet negativ oder positiv ausfällt.

Wie verteilt sich die Polarity im Bezug auf die Tweets mit Schiedsrichtererwähnungen. Dabei wurden Duplikate entfernt

9 Zusammenfassung

Es hat sich bewährt, dass der Fußballsport eine sehr angesehene Sportart ist und bis heute an Ansehen gewonnen hat. Es ist sogar so beliebt, dass es die beliebteste Sportart geworden ist. Hinzu kommt, dass alle vier Jahre die Weltmeisterschaft stattfindet. Die Fussball Weltmeisterschaft zählt zu den größten Sportereignissen auf der Welt. Mannschaften aus aller Welt treffen sich für dieses Ereignis. Für die Analyse der Tweets haben wir Python als Programmiersprache gewählt und haben Datensätze von der Universität Augsburg zur Verfügung gestellt bekommen. Diese beinhalten 47,4 Millionen Tweets, die während der Weltmeisterschaft 2014 aufgenommen worden sind. Für die Analyse haben wir Spark verwendet. Dies ist ein bekanntest Framework, welches für Big-Data Analyse verwendet wird. Vor der Ausarbeitung der Analyse haben wir Hypothesen aufgestellt, die im Zusammenhang mit der Weltmeisterschaft entstehen. Da diese Veranstaltung ein Wettbewerb von unterschiedlichen Nationen ist, ist ein hohes Sentiment gegeben. Daraufhin haben wir untersucht, welche Vorgehensweise die besten Resultate erzielt. Das Ergebnis war die Auswertung ohne Benutzung von N-Grams. Vergleichsweise haben sowohl die normale Polarity Analyse, als auch Afinn Analyse gute Resultate erzielt. Außerdem haben wir eine Abbildung zur NLP angefertigt, die unser Vorgehen nochmals bildlich darstellt. Des Weiteren hat die Speicherung der JSON-Dateien als csv Dateien am meisten Zeit in Anspruch genommen, als auch die Ausführung der Anfragen. Der Grund dafür ist die große Anzahl der Tweets. Danach wurden alle Tweets analysiert, wobei Emojis aufgrund der mangelnden Untersuchungen nicht mit einbezogen wurden. Anfangs haben wir in Städte, Länder, Zeitzonen und Sprachen gegliedert, um zu untersuchen, ob Auffälligkeiten und Untergruppen vorhanden sind. Es hat sich herausgestellt, dass ein hoher Anteil der Tweets aus Amerika kommt. Dies hat sich auch nach der Analyse der Zeitzonen bestätigt. Daraufhin haben wir die am meisten verwendeten Hashtags ausgegeben und haben diese analysiert. Die Analyse hat ergeben, dass die meisten Hashtags den Namen Weltmeisterschaft und Brasilien haben aufgrund der Austragung der Weltmeisterschaft in Brasilien. Außerdem hat sich gezeigt, dass die am meisten retweeteten Tweets mehr positive als negative Tweets sind. In den nächsten Schritten haben wir mit der Analyse des Sentiments begonnen. Zudem haben wir untersucht, ob die Anzahl der Retweets mit dem Sentiment zusammenhängt. Demnach sind wir zu dem Ergebnis gekommen, dass sich eine sehr große Anzahl an Tweets als neutrale Nachrichten herausgestellt haben. Mit anderen Worten sind die meisten Tweets weder positiv, noch negativ in Erscheinung getreten. Unser Verdacht hat sich also als falsch erwiesen, dass die Nachrichten der User aufgrund des hohen Sentiments getweetet werden. Zudem hat sich herausgestellt, dass sich ein Großteil unserer Hypothesen als falsch erwiesen haben. Aber unsere Hypothese, dass die am häufigsten Tweets über Schiedsrichter negativ sind, hat sich als wahr erwiesen. Daraus kann man schließen, dass Vermutungen und Vorurteile, wodurch unsere Hypothesen entstanden sind, sich nur selten als wahr erweisen.

A Anhang

A.1 Referenzen

- [1] Kuhlman, Dave. "Python Book: Beginning Python, Advanced Python, and Python Exercises". Section 1.1. Archived from the original (PDF) on 23 June 2012
- [2] Rossum, Guido Van (20 January 2009). "The History of Python: A Brief Timeline of Python". The History of Python. Archived from the original on 5 June 2020. Retrieved 5 March 2021
- [3] Stack Overflow Developer Survey 2020. Stack Overflow. Archived from the original on 2 March 2021. Retrieved 5 March 2021
- [4] "The State of Developer Ecosystem in 2020 Infographic". JetBrains: Developer Tools for Professionals and Teams. Archived from the original on 1 March 2021. Retrieved 5 March 2021
- [5] index — TIOBE - The Software Quality Company". www.tiobe.com. Archived from the original on 25 February 2018. Retrieved 2 February 2021. Python has won the TIOBE programming language of the year award! This is for the fourth time in the history, which is a record! The title is awarded to the programming language that has gained most popularity in one year.
- [6] PPYPL PopularitY of Programming Language index". pypl.github.io. Archived from the original on 14 March 2017. Retrieved 26 March 2021
- [7] Apache Spark, Spark Apache, 2018
- [8] Big data analytics on Apache Spark, Salman Salloum, Ruslan Dautov, Xiaojun Chen, Patrick Xiaogang Peng, Joshua Zhexue Huang, 2016
- [9] <https://www.welt.de/sport/fussball/wm-2014/gallery129434023/Luis-Suarez-Ein-Stuermer-beisst-sich-durch.html>cs-lazy-picture-placeholder-01c4eedaca.png, 27.08.2021, Quelle: REUTERS/GK
- [10] <https://www.welt.de/sport/fussball/wm-2014/article129510643/Das-sind-die-Konsequenzen-der-Strafe-fuer-Suarez.html>, 27.08.2021
- [11] <https://www.youtube.com/watch?v=sX3jm3oYUIo>, 27.08.2021, Snickers DACH
- [12] <https://de.wikipedia.org/wiki/Emoji>, 28.08.2021
- [13] Annual Review of Information Science and Technology, Chapter 2: Natural language Processing, Gobinda G. Chowdhury, University of Strathclyde, 2005
- [14] Natural Language Processing, Elizabeth D. Liddy, 2001

-
- [15] <https://datasolut.com/natural-language-processing-einfuehrung/>, 30.08.2021, Laurenz Wuttke
- [16] Natural Language Processing, Abhimanyu Chopra, Abhinav Prashar, Chandresh Sain, 2013
- [17] <https://www.thomashutter.com/facebook-wm-final-sprengt-alles-rekorde-280-millionen-interaktionen-auf-facebook/>, 06.09.2021, Thomas Hutter
- [18] <https://themoney.co/de/top-10-des-sports-les-plus-populaires-dans-le-monde-en-2020/>, 09.09.2021

B Inhalt der CD

Im Anhang dieser Arbeit befindet sich eine CD mit folgendem Inhalt:

- Diese Arbeit als PDF Datei - im Ordner *PDF*
- Der Sourcecode der Implementierung dieser Arbeit - im Ordner *SRC*
- Die Implementierung als .jar-Datei - im Ordner *JAR*
- Den $\text{\LaTeX}$ -Sourcecode - im Ordner *LATEX*

C Erklärung

Ich erkläre hiermit, dass ich die Arbeit eigenhändig, ohne unzulässige Hilfsmittel und unter Angabe aller Quellen angefertigt habe.

Augsburg, den 23. September 2021

Vorname Name